Explainability delle predizioni di FOLD sul traffico ODoH

Analisi closed-world, defense e open-world

1 Introduzione

Il lavoro riguarda l'aggiunta di explainability a FOLD. L'obiettivo è capire quali informazioni contribuiscono alle sue predizioni e rendere più leggibile il comportamento del modello sulle tracce ODoH analizzate. Come primo passo ho analizzato la Random Forest con TreeSHAP; ho poi implementato una spiegazione end-to-end che parte dalla traccia e ricalcola tutti gli input prima di valutare l'output finale di FOLD.

Il report racconta due fasi successive del lavoro. Nella prima ho implementato e validato la pipeline attraverso uno studio dettagliato su Instagram, utilizzando una singola repetition per configurazione. Ho analizzato baseline, defense e open-world, distinguendo le spiegazioni multiclass da quelle binary. Questa fase ha permesso di verificare concretamente il comportamento delle spiegazioni RF e FOLD e di leggere i contributi insieme alle performance.

Le Sezioni 2–6 descrivono questo studio iniziale: i campioni, le reference, i risultati numerici e le figure si riferiscono al relativo esperimento single-run. Successivamente ho esteso l'analisi a più siti e cinque training run per configurazione, per verificare quanto le osservazioni sul caso Instagram fossero diffuse e quanto dipendessero dai campioni e dai modelli osservati. La Sezione 7 presenta questa seconda campagna, con target multiclass dinamico, aggregazione per sito, CI al 95%, dominant-group analysis, heatmap e delta paired rispetto alla baseline. Il protocollo FAST riduce il budget della sola explainability, mantenendo completi i training.

Le due fasi rispondono quindi a domande complementari: lo studio iniziale approfondisce un caso controllato, mentre l'estensione verifica gli stessi strumenti su un insieme più ampio di siti e configurazioni. Le tabelle originali sono conservate in appendice e affiancate da quelle cross-run.

2 Metodologia di explainability

2.1 TreeSHAP sulla Random Forest

La Random Forest utilizza 97 feature: 33 statistiche aggregate e 64 conteggi dell'istogramma delle dimensioni dei pacchetti. Per spiegare la RF ho utilizzato TreeSHAP, che assegna a ciascuna feature un contributo alla probabilità della classe target rispetto a un riferimento. Un contributo positivo aumenta questa probabilità; uno negativo la diminuisce.

I campioni da spiegare sono tracce del test set sulle quali vogliamo capire la decisione del modello. Le reference sono invece tracce di training utilizzate per definire il riferimento rispetto al quale vengono calcolati i contributi. In questo contesto, una reference non indica necessariamente traffico background. La classe target è la classe di cui spieghiamo la probabilità: nella baseline ho scelto la classe 8, `instagram.com`, utilizzando 16 tracce Instagram di test e 64 reference di training.

Una spiegazione locale riguarda una singola traccia e mostra quali feature aumentano o diminuiscono la probabilità del target. Aggregando più spiegazioni locali possiamo osservare quali feature hanno mediamente contributi più grandi nel cohort analizzato. Nei grafici globali uso la media dei valori assoluti: questa misura indica la magnitudine del contributo, mentre per conoscerne la direzione occorre considerare il segno.

TreeSHAP spiega la Random Forest, non automaticamente la previsione finale di FOLD. Questa analisi è stata quindi un primo livello di explainability e un modo per verificare il funzionamento della pipeline prima di passare alla spiegazione completa di FOLD.

2.2 Explainability end-to-end di FOLD

Gli input utilizzati da FOLD derivano tutti dalla stessa traccia ODoH. Non sarebbe corretto modificare soltanto la rappresentazione sequenziale lasciando inalterate le feature della Random Forest o le sue probabilità: i diversi input non rappresenterebbero più la stessa traccia e la spiegazione riguarderebbe una combinazione incoerente di informazioni.

Per questo motivo ho implementato un predictor end-to-end. Il predictor riceve una traccia, applica l'Encoder e il preprocessing, ricava le feature della RF e calcola le probabilità con la Random Forest finale. Ricostruisce poi gli input sequenziali e statistici di FOLD e valuta il modello usando anche le probabilità RF appena ottenute. Lo schema seguito è:

Traccia perturbata
↓
Encoder / preprocessing
↓
Feature Random Forest
↓
Random Forest finale
↓
Probabilità RF
↓
Input sequenziali e statistici FOLD
↓
FOLD
↓
Probabilità della classe target

Ogni volta che l'explainer crea una traccia ibrida, tutti gli input vengono ricalcolati da quella stessa traccia. In questo modo la spiegazione comprende anche le variazioni delle informazioni fornite dalla RF. L'Encoder e i modelli già addestrati vengono usati per la previsione: durante SHAP il modello non viene riaddestrato. Per l'analisi multiclass spiego `multi_output`, cioè l'output finale multiclass di FOLD, selezionando la probabilità della classe target.

2.3 Valori Shapley esatti per gruppi

Per spiegare l'output finale ho diviso ogni traccia in quattro gruppi consecutivi e bilanciati di risoluzioni complete, indicati con G1, G2, G3 e G4. G1 contiene la parte iniziale secondo l'ordine delle risoluzioni e G4 quella finale. Sono blocchi relativi alla lunghezza della traccia, non quattro intervalli di uguale durata temporale. Anche ogni traccia reference viene suddivisa nello stesso modo.

Per valutare il contributo di un gruppo, l'explainer costruisce tracce ibride: mantiene alcuni gruppi del campione da spiegare e sostituisce gli altri con i gruppi corrispondenti di una traccia reference. Ogni combinazione di gruppi mantenuti, chiamata coalizione, viene valutata con il predictor end-to-end. Il procedimento viene ripetuto sulle reference e le probabilità ottenute vengono mediate.

Il valore Shapley di un gruppo riassume quanto cambia la probabilità quando quel gruppo viene aggiunto alle diverse combinazioni degli altri. Con quattro gruppi ci sono soltanto $2^4 = 16$

coalizioni: è quindi possibile valutarle tutte e calcolare il valore esatto per questo raggruppamento e per le reference scelte. La coalizione vuota corrisponde alle reference e quella completa alla traccia originale. Indicando con $N = \{1, 2, 3, 4\}$ l'insieme dei gruppi e con $v_x(S)$ la probabilità media per la coalizione S, il contributo del gruppo g è:

$$\phi_g(x) = \sum_{S \subseteq N \setminus \{g\}} \frac{|S|!\,(4 - |S| - 1)!}{4!} \left[v_x(S \cup \{g\}) - v_x(S) \right]. \tag{1}$$

La formula viene applicata ai quattro gruppi. Nella baseline ho spiegato 15 tracce Instagram, con target class 8, quattro gruppi, 16 reference di training e seed 0. I contributi con segno descrivono la differenza tra la probabilità della traccia e la probabilità media delle reference; la media dei valori assoluti permette di confrontare le magnitudini dei quattro gruppi sul cohort.

Le tracce ibride sono create appositamente dall'explainer per osservare come cambia la predizione e non rappresentano necessariamente traffico reale. I gruppi indicano una posizione relativa nella traccia, non quattro fasi temporali fisiche. I valori descrivono il comportamento del modello rispetto alle reference scelte e non dimostrano una relazione causale nel traffico reale.

3 Configurazione sperimentale

3.1 Dataset e configurazioni

Il dataset monitored, `data/odoh_traces.csv`, contiene 100 siti, 2.834 tracce di caricamento di pagina e 54.155 righe di risoluzioni ODoH. Ogni riga rappresenta una risoluzione.

Lo split assegna il 65% delle tracce al training, il 10% alla validazione e il 25% al test: rispettivamente 1.842, 283 e 709 tracce monitored. Ho eseguito una sola repetition per configurazione. La Tabella 1 riassume la baseline, le cinque configurazioni open-world e le venti configurazioni defense.

Tabella 1: Le 26 configurazioni sperimentali. Le defense sono valutate senza background; le configurazioni open-world senza defense.

Scenario	Rapporto background o intensità defense	Configurazioni
Baseline	Senza background e defense	1
Open-world	Background 30/40/50/60/70%	5
Padding	Intensità 10/30/50/70/100%	5
Dummy	Intensità 10/30/50/70/100%	5
Fragmentation	Intensità 10/30/50/70/100%	5
Combined	Ogni meccanismo al 10/30/50/70/100%	5
Totale		26

Il padding modifica le dimensioni, dummy aggiunge record e fragmentation suddivide i payload che soddisfano le condizioni previste. L'intensità indica la probabilità di applicazione del meccanismo. Combined applica tutti e tre i meccanismi alla stessa intensità. Le defense sono applicate a training, validazione e test, addestrando i modelli per ciascuna configurazione, senza background.

Nello scenario open-world il background proviene da un insieme sintetico comune. Il rapporto indica la frazione prevista di background nel totale delle tracce; queste configurazioni non includono defense.

3.2 Campioni utilizzati per le spiegazioni

Le metriche di performance sono calcolate sull'intero test set, mentre le spiegazioni riguardano i campioni della Tabella 2. Le stesse 15 tracce Instagram vengono utilizzate per la baseline FOLD,

le defense, l'analisi multiclass open-world e il cohort monitored dell'analisi binary. Per TreeSHAP uso un insieme separato di 16 tracce Instagram.

Tabella 2: Campioni spiegati e reference di training. Per FOLD si usano quattro gruppi di risoluzioni; per la RF, 97 feature.

Analisi	Campioni di test	Reference	Unità
Baseline RF	16 Instagram	64 monitored	97 feature
Baseline FOLD	15 Instagram	16 monitored	4 gruppi
FOLD con defense	Stesse 15 Instagram	16 monitored	4 gruppi
Open-world multiclass	Stesse 15 Instagram	16 monitored	4 gruppi
Open-world binary	15 monitored + 15 background	8 + 8 miste	4 gruppi

3.3 Metriche

L'accuracy è la frazione di predizioni corrette; nello scenario open-world comprende anche il corretto riconoscimento del background. La macro-F1 è la media degli F1 delle classi monitored: il background contribuisce come esempio negativo, ma non è incluso come classe nella media.

Il TPR indica la quota di tracce monitored riconosciute come tali. Il FPR indica la quota di tracce background erroneamente riconosciute come monitored. Entrambi sono calcolati con soglia > 0.5. La ROC AUC riassume la capacità di distinguere monitored e background considerando tutte le soglie. Per FOLD il punteggio è l'output binary; per la RF si usa la massima probabilità multiclass riscalata. Le metriche sono espresse tra 0 e 1.

4 Risultati closed-world

4.1 Performance

Nella baseline, senza defense e background, la RF raggiunge accuracy 0.9887 e macro-F1 0.9886; FOLD raggiunge accuracy 0.9873 e macro-F1 0.9832. Entrambi ottengono quindi performance elevate. I valori arrotondati sono riportati nella Tabella 3.

4.2 TreeSHAP RF

La Figura 1 mostra l'importanza delle feature per la probabilità della classe 8. Le feature con i maggiori contributi medi assoluti sono la deviazione standard delle dimensioni dei pacchetti (0.0453), la dimensione media (0.0403) e la dimensione media delle risposte del target (0.0397). Tra le feature principali compaiono anche conteggi dell'istogramma delle dimensioni e statistiche delle dimensioni per ruolo. L'ultima barra somma i contributi delle altre 83 feature e va letta come un'aggregazione.

4.3 Grouped Shapley FOLD

Nelle tracce Instagram selezionate, il primo blocco relativo presenta mediamente il contributo assoluto maggiore, seguito da G2. I valori per G1–G4 sono rispettivamente 0.2950, 0.2146, 0.1654 e 0.1687: G3 e G4 risultano più bassi, ma mantengono contributi apprezzabili (Figura 2).

I contributi dei gruppi nella baseline sono positivi. La probabilità media Instagram è 0.8451, rispetto a una probabilità media delle reference di 0.0014. Questa osservazione riguarda il cohort Instagram analizzato. Le magnitudini RF e FOLD non sono direttamente confrontabili, perché le due analisi spiegano modelli diversi con feature o gruppi, reference e campioni differenti.

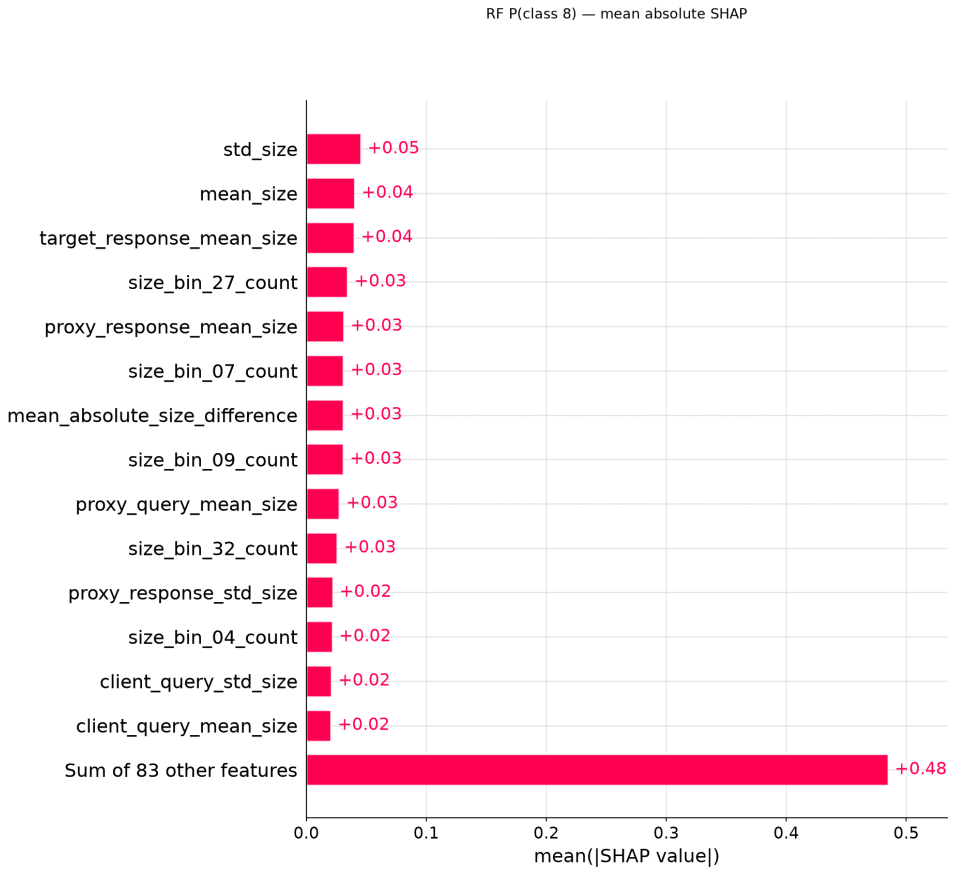


Figura 1: TreeSHAP della RF per P(Instagram): 16 tracce di test e 64 reference di training. Le barre mostrano i contributi medi assoluti; l'ultima riunisce le altre 83 feature.

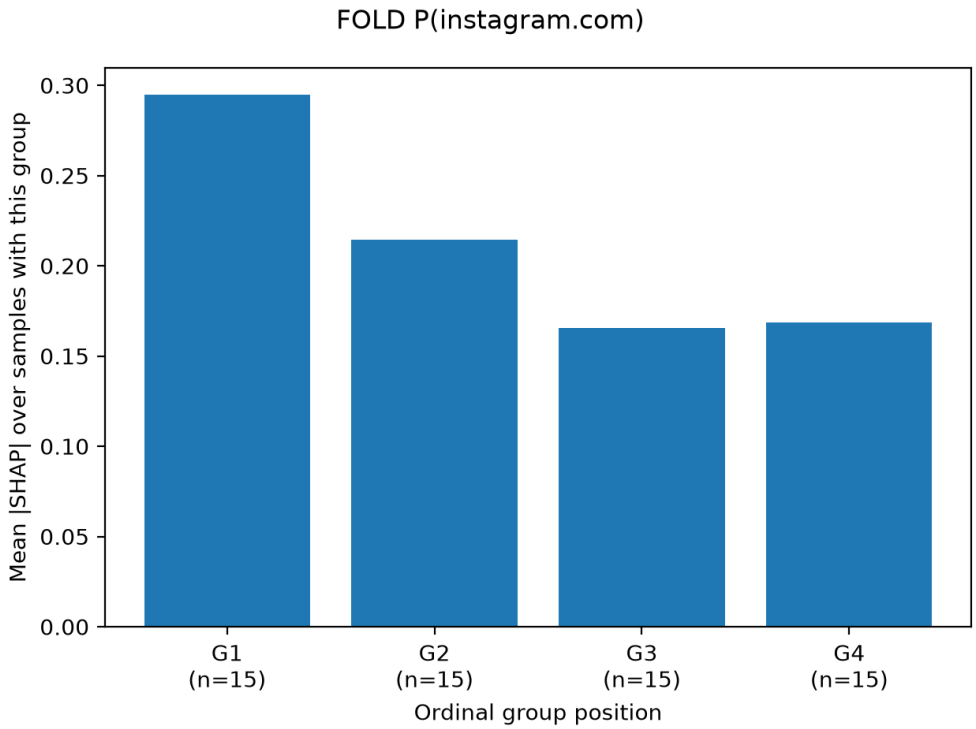


Figura 2: Contributi medi assoluti grouped Shapley di FOLD per P(Instagram): 15 tracce di test, 16 reference e quattro gruppi consecutivi di risoluzioni.

5 Risultati con defense

5.1 Performance

La Tabella 3 riporta tutte le 20 configurazioni e la baseline per RF e FOLD; la Figura 3 mostra l'accuracy di FOLD. Il padding riduce soprattutto le performance alle intensità più alte: a 1.00 FOLD raggiunge accuracy 0.578 e macro-F1 0.571. Con dummy l'accuracy rimane elevata, tra 0.979 e 0.990, con variazioni non monotone.

Fragmentation presenta una degradazione più moderata rispetto a padding e combined: l'accuracy FOLD scende a 0.928 a intensità 0.70 e risale a 0.941 a 1.00. Combined mostra una forte riduzione alle intensità intermedie e alte, con il minimo di accuracy 0.547 a 0.70 e un recupero a 0.732 a 1.00. Questo recupero è quanto osservato nella singola run.

Tabella 3: Performance della baseline e delle 20 configurazioni defense, senza background. Accuracy e macro-F1 sono calcolate su tutto il test set.

Defense	Intensità	RF accuracy	RF macro-F1	FOLD accuracy	FOLD macro-F1
Baseline	0.00	0.989	0.989	0.987	0.983
Padding	0.10	0.979	0.976	0.979	0.980
Padding	0.30	0.953	0.952	0.962	0.959
Padding	0.50	0.890	0.891	0.904	0.901
Padding	0.70	0.745	0.746	0.756	0.758
Padding	1.00	0.477	0.461	0.578	0.571
Dummy	0.10	0.983	0.978	0.990	0.989
Dummy	0.30	0.976	0.969	0.983	0.980
Dummy	0.50	0.975	0.969	0.980	0.976
Dummy	0.70	0.972	0.965	0.990	0.988
Dummy	1.00	0.970	0.966	0.979	0.974
Fragmentation	0.10	0.979	0.974	0.987	0.987
Fragmentation	0.30	0.963	0.957	0.966	0.961
Fragmentation	0.50	0.938	0.933	0.953	0.952
Fragmentation	0.70	0.922	0.916	0.928	0.926
Fragmentation	1.00	0.925	0.920	0.941	0.939
Combined	0.10	0.959	0.955	0.959	0.958
Combined	0.30	0.839	0.840	0.839	0.840
Combined	0.50	0.643	0.632	0.674	0.678
Combined	0.70	0.496	0.477	0.547	0.528
Combined	1.00	0.654	0.640	0.732	0.729

5.2 Probabilità Instagram e contributi dei gruppi

La Figura 4 mostra i contributi dei quattro gruppi per ogni defense, mentre la Figura 5 riporta la probabilità media Instagram sulle stesse 15 tracce. La Tabella 10 in appendice contiene tutti i valori.

Padding. Alle intensità più alte diminuiscono sia la probabilità Instagram sia le attribuzioni (Figura 4a). A 1.00 la probabilità media è 0.0262 e i contributi medi assoluti sono compresi tra 0.0041 e 0.0078. Alle intensità basse l'andamento è diverso: a 0.10 la probabilità è 0.9250, superiore alla baseline 0.8451.

Dummy. I contributi rimangono relativamente consistenti e G1 mantiene la magnitudine maggiore a tutte le intensità (Figura 4b). La probabilità media Instagram varia tra 0.7965 e

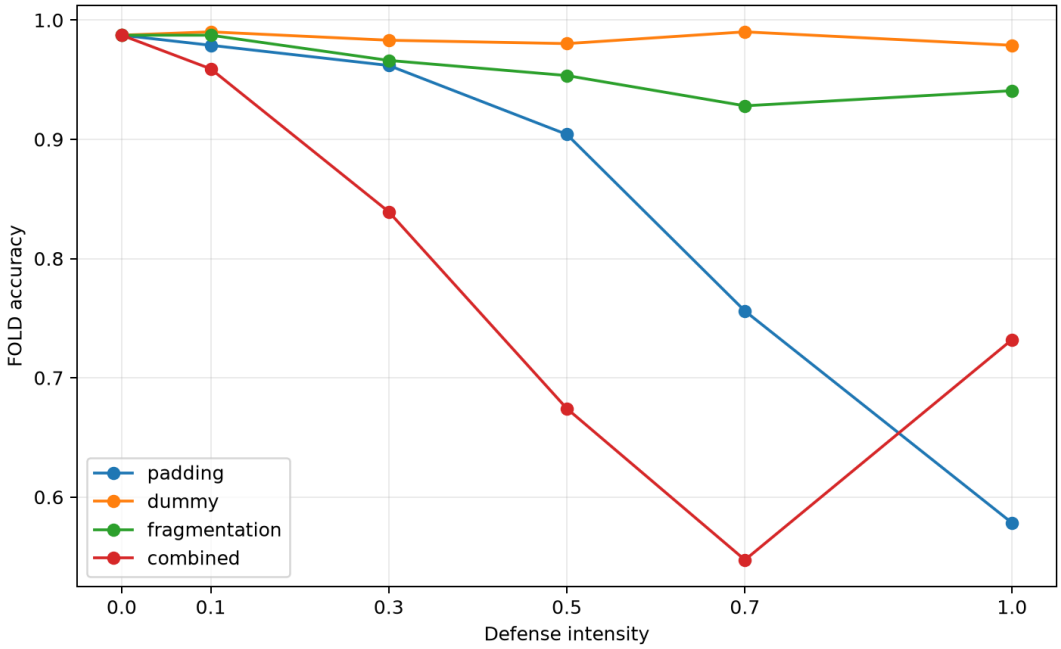
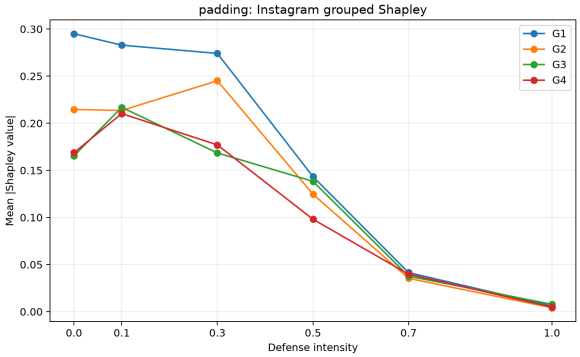


Figura 3: Accuracy di FOLD per le quattro defense, senza background, al variare dell'intensità.

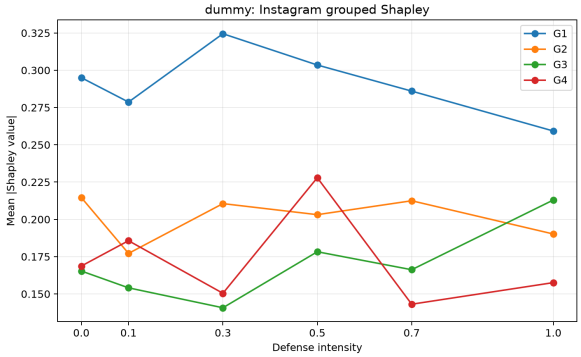
0.9137, senza un andamento monotono. Rispetto alle intensità alte di padding e combined, le attribuzioni rimangono su valori più vicini alla baseline.

Fragmentation. G1 rimane il gruppo con il contributo medio assoluto maggiore, ma la distanza dagli altri gruppi si riduce (Figura 4c). A 1.00 G1 vale 0.2362, mentre G3 e G4 valgono 0.1963 e 0.2074, superiori ai rispettivi valori di baseline. La probabilità Instagram è 0.8373 a 1.00; il minimo osservato è 0.6807 a 0.50.

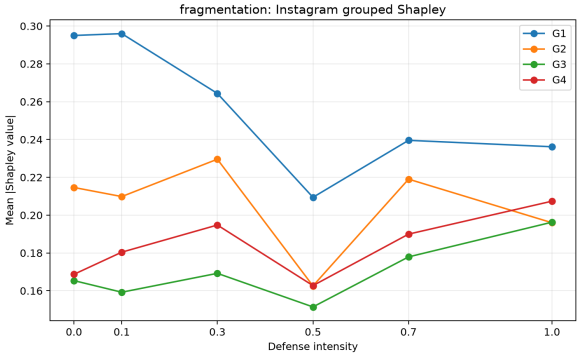
Combined. A 0.10 G4 e G3 superano G1 e G2 (Figura 4d), con probabilità media 0.8410. A 0.50 e 0.70 la probabilità scende a 0.0659 e 0.0393 e tutti i contributi si riducono molto. A 1.00 si osserva un recupero della probabilità, pari a 0.2256, e delle attribuzioni, che restano inferiori alla baseline.



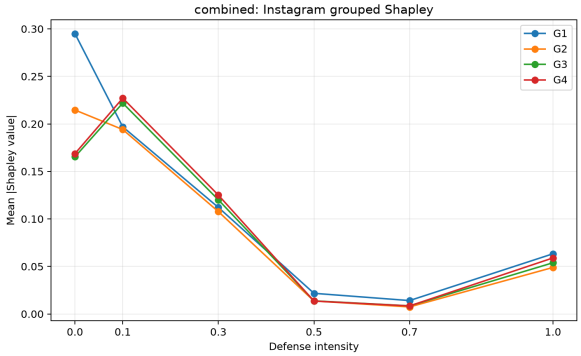
(a) Padding.



(b) Dummy.



(c) Fragmentation.



(d) Combined.

Figura 4: Contributi medi assoluti di FOLD sulle stesse 15 tracce Instagram per le quattro defense. L'intensità zero indica la baseline. I pannelli hanno scale verticali diverse.

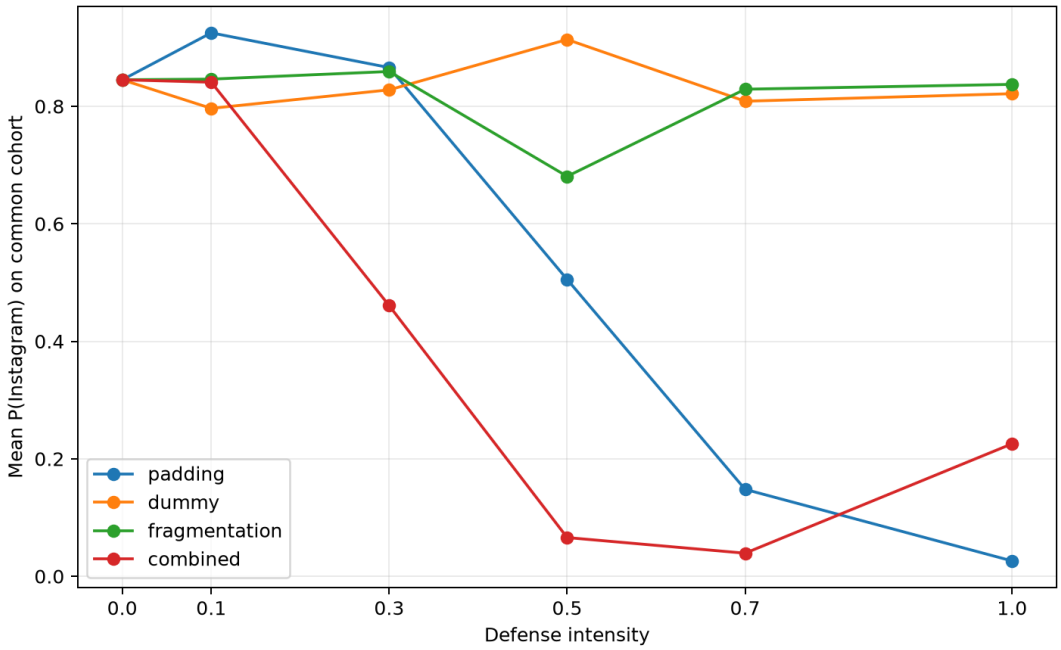


Figura 5: Probabilità media Instagram assegnata da FOLD al cohort selezionato, al variare della defense e dell'intensità.

6 Risultati open-world

6.1 Open-world: approccio di explainability

Nel closed-world e nell'analisi multiclass open-world spiego `multi_output`, cioè la probabilità assegnata al sito target, in questo caso $P(\text{Instagram})$. Nello scenario open-world è disponibile anche `binary_output`$= P(\text{monitored})$, che risponde a una domanda diversa: la traccia appartiene a uno dei siti monitorati oppure al background?

Per questo ho eseguito due analisi. La spiegazione multiclass permette di osservare come cambiano i contributi alla probabilità Instagram quando aumenta la quota di background. La spiegazione binary permette invece di capire quali gruppi spingono la decisione verso monitored oppure verso background. Entrambe utilizzano il predictor end-to-end e lo stesso raggruppamento G1–G4.

Per la binary ho spiegato 15 campioni monitored e 15 campioni background per rapporto, usando 8 reference monitored e 8 reference background di training. Le 16 reference sono comuni ai cinque rapporti. Un valore ϕ positivo aumenta $P(\text{monitored})$ rispetto al riferimento; un valore negativo la diminuisce e spinge quindi la decisione verso background.

6.2 Performance

Le Tabelle 4 e 5 riportano i risultati dei cinque rapporti di background. FOLD ha accuracy, TPR e ROC AUC maggiori della RF in tutti i rapporti. La macro-F1 è maggiore a 0.40, 0.50 e 0.60, ma inferiore a 0.30 e 0.70.

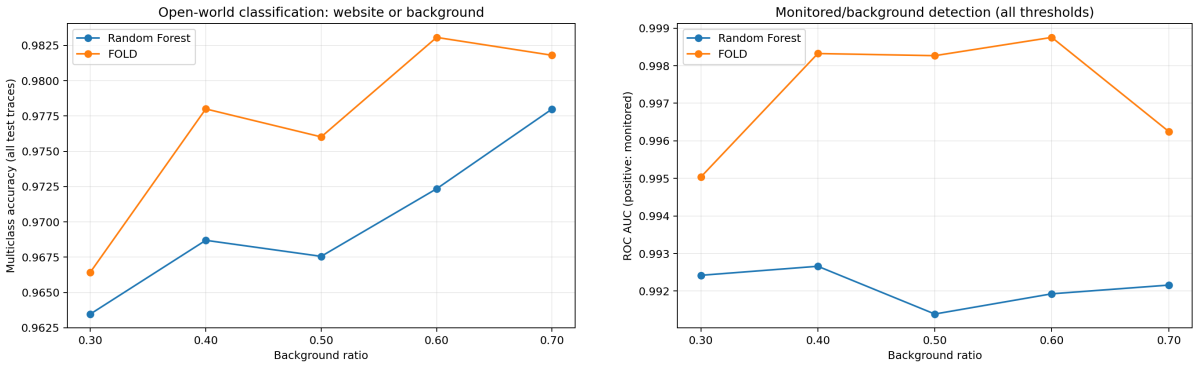
Il FPR di FOLD è maggiore a 0.30, 0.40 e 0.50, inferiore a 0.60 e uguale a quello della RF a 0.70 (0.011487 prima dell'arrotondamento). A 30% di background FOLD riconosce una quota maggiore di traffico monitored, ma presenta anche un FPR maggiore della RF: TPR/FPR sono 0.984/0.053 per FOLD e 0.955/0.013 per RF. Macro-F1 e FPR non mostrano quindi lo stesso vantaggio in tutti i rapporti. La Figura 6 riassume accuracy (Figura 6a) e AUC (Figura 6b).

Tabella 4: Performance open-world nei cinque rapporti di background. L'accuracy include il riconoscimento del background; la macro-F1 riguarda i siti monitored.

Background	RF accuracy	RF macro-F1	FOLD accuracy	FOLD macro-F1
0.30	0.963	0.969	0.966	0.967
0.40	0.969	0.969	0.978	0.978
0.50	0.968	0.965	0.976	0.969
0.60	0.972	0.963	0.983	0.970
0.70	0.978	0.961	0.982	0.959

Tabella 5: Riconoscimento del traffico monitored nello scenario open-world. TPR e FPR usano la soglia > 0.5; ROC AUC considera tutte le soglie.

Background	RF TPR	RF FPR	RF AUC	FOLD TPR	FOLD FPR	FOLD AUC
0.30	0.955	0.013	0.992	0.984	0.053	0.995
0.40	0.955	0.008	0.993	0.989	0.025	0.998
0.50	0.955	0.018	0.991	0.984	0.021	0.998
0.60	0.955	0.015	0.992	0.982	0.009	0.999
0.70	0.955	0.011	0.992	0.979	0.011	0.996



(a) Accuracy sul test set.

(b) ROC AUC monitored/background.

Figura 6: Accuracy e ROC AUC di RF e FOLD nei cinque rapporti open-world, senza defense.

6.3 Spiegazioni multiclass

La Figura 7 e la Tabella 11 non mostrano un andamento monotono evidente dei contributi al crescere del background. G1 e G2 sono i due gruppi con le attribuzioni medie assolute maggiori in tutti i rapporti; G2 supera G1 a 0.30 e 0.60.

La probabilità media Instagram varia tra 0.6257 e 0.8690, con il massimo a 0.50. I contributi medi con segno dei quattro gruppi sono positivi. Questi risultati riguardano le stesse 15 tracce Instagram nei cinque rapporti.

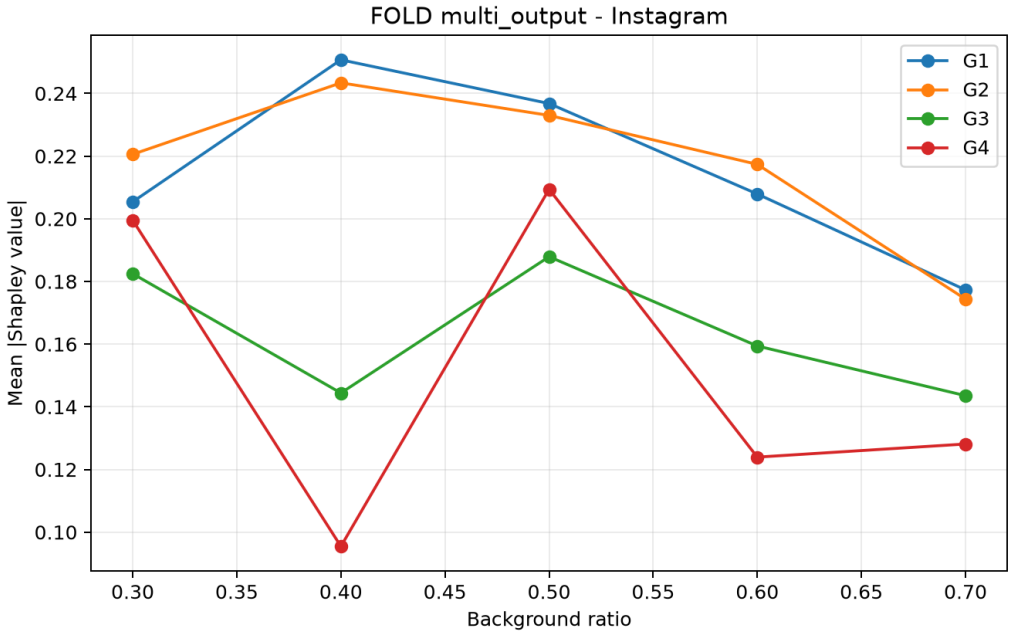


Figura 7: Contributi multiclass medi assoluti di FOLD sulle stesse 15 tracce Instagram nei cinque rapporti di background.

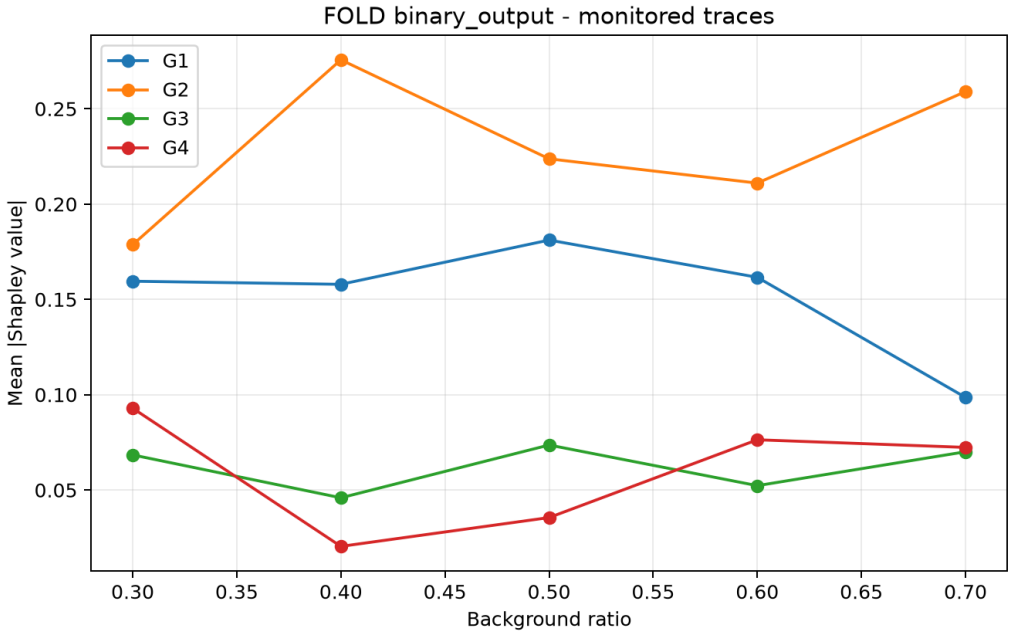
6.4 Spiegazioni binary

La Figura 8 mostra le magnitudini dei contributi per i cohort monitored e background. Le Tabelle 12 e 13 riportano probabilità, valori assoluti e valori con segno. La probabilità media delle reference miste è circa 0.5.

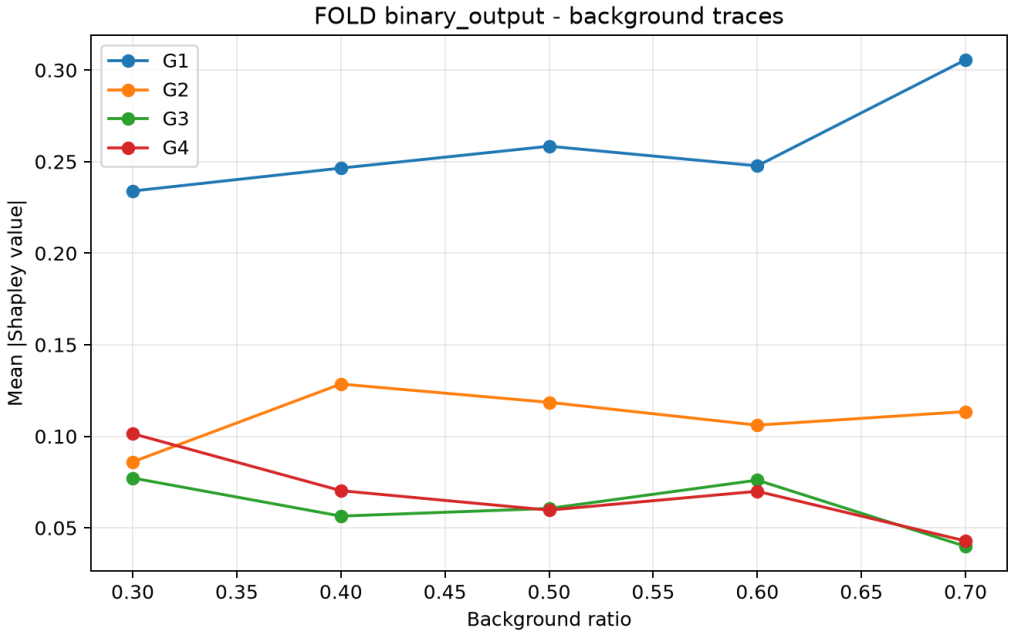
Nel cohort monitored i contributi medi sono positivi e aumentano quindi $P(\text{monitored})$. G2

ha la magnitudine media maggiore in tutti i rapporti, seguito da G1 (Figura 8a). La probabilità media monitored supera 0.9995 in ogni rapporto. Il segno positivo della media non implica che ogni contributo individuale sia positivo.

Nel cohort background i contributi medi di tutti i gruppi sono negativi: diminuiscono $P(\text{monitored})$ e spostano la predizione verso background. G1 ha la magnitudine media maggiore in tutti i rapporti (Figura 8b). La probabilità media monitored varia tra 0.0001 e 0.0677. I campioni background cambiano tra i rapporti: non si tratta dello stesso insieme di tracce confrontato cinque volte.



(a) Cohort monitored comune.



(b) Cohort background diversi tra i rapporti.

Figura 8: Contributi binary medi assoluti di FOLD per 15 tracce monitored e 15 background, con 16 reference miste. I contributi con segno sono riportati nella Tabella 13.

7 Estensione cross-run e analisi multi-sito

Lo studio iniziale ha approfondito il cohort Instagram su una singola repetition. Per verificare se i risultati fossero confermati su più siti e modelli addestrati in repetition diverse, ho esteso l'analisi a una campagna cross-run, introducendo aggregazione multi-sito, intervalli di confidenza e confronti con la baseline.

7.1 Disegno sperimentale cross-run

Il dataset monitored, `data/odoh_traces.csv`, contiene 100 siti, 2.834 tracce di caricamento di pagina e 54.155 righe di risoluzioni ODoH. Ogni riga rappresenta una risoluzione. Lo split assegna il 65% delle tracce al training, il 10% alla validazione e il 25% al test: 1.842, 283 e 709 tracce monitored in ciascuna repetition. I cinque split registrati conservano queste numerosità, ma cambiano le tracce assegnate.

La campagna comprende cinque run addestrate per configurazione, con experiment ID da 1 a 5: 26 configurazioni per 5 repetition, cioè 130 job. Gli scenari restano quelli della Tabella 1 dello studio iniziale. Il padding modifica le dimensioni, dummy aggiunge record e fragmentation suddivide i payload che soddisfano le condizioni previste. L'intensità indica la probabilità di applicazione del meccanismo; combined applica tutti e tre alla stessa intensità. Le defense sono applicate a training, validazione e test, addestrando i modelli per ciascuna configurazione, senza background.

Nell'open-world il background proviene da un insieme sintetico comune. Il rapporto indica la frazione prevista di background nel totale delle tracce; queste configurazioni non includono defense.

Nel nuovo studio multiclass il target diventa dinamico: per ogni osservazione x viene spiegata $P_{\mathrm{FOLD}}(y_x \mid x)$, dove y_x è il suo vero sito, anche quando la predizione è errata. Per RF viene selezionata analogamente la probabilità della classe reale. Non viene quindi spiegata sempre Instagram né sempre la classe predetta. I pannelli Instagram della nuova campagna rimangono utili per confrontare un caso specifico con il primo studio, mentre il risultato globale riguarda tutti i siti del cohort pertinente.

Le metriche mantengono il significato dello studio iniziale. Nei risultati cross-run il FPR di detection, identificato da `detection.fpr`, rimane distinto dal macro-FPR one-vs-rest presente nei CSV come `fpr`.

7.2 Dal protocollo completo al protocollo FAST

Il protocollo cross-run inizialmente progettato prevedeva più spiegazioni per sito e reference più numerose. Il costo grouped Shapley cresce perché ogni osservazione richiede tutte le 16 coalizioni G1–G4, valutate rispetto alle reference attraverso l'intera pipeline: `Encoder.forest()`, RF finale, `Encoder.sequence()` e FOLD. Moltiplicando questo lavoro per siti, osservazioni, reference, configurazioni e repetition, la campagna diventava poco praticabile.

È stato quindi introdotto il protocollo FAST, che riduce soltanto osservazioni sottoposte a XAI e reference. Restano invariati modelli addestrati, cinque repetition, 26 configurazioni, split, seed del training, architettura, loss, preprocessing, defense, definizione G1–G4 e output spiegati. Si tratta di una riduzione del budget di explainability, non di un training abbreviato o di un modello semplificato.

7.3 Cohort e problema dei 92 siti

Le metriche di performance sono calcolate sui test set completi dei cinque modelli per configurazione. Le spiegazioni riguardano invece i sottoinsiemi held-out della Tabella 6. Ogni osservazione è identificata dalla traccia e dalla run alla quale è assegnata; appartiene al test di quella run. I

record FAST fissano 300 osservazioni RF, tutte distinte, con tre osservazioni per ciascuno dei 100 siti. Lo stesso cohort RF viene mantenuto nelle diverse configurazioni.

L'obiettivo iniziale era spiegare anche FOLD su tutti i 100 siti. Tuttavia G1–G4 richiede almeno quattro risoluzioni ODoH complete: nell'unione dei test delle cinque repetition soltanto 92 siti dispongono di almeno una traccia eleggibile. Il cohort grouped FOLD contiene quindi 266 osservazioni e 266 tracce distinte, da una a tre per sito, mantenute nelle configurazioni baseline, defense e open-world multiclass e nel cohort binary monitored. Le reference grouped rispettano lo stesso vincolo strutturale.

La scelta conserva il significato dei quattro gruppi: non vengono create tracce eleggibili artificialmente, introdotti gruppi adattivi o ridefiniti G1–G4 come quartili di pacchetti per raggiungere 100 siti. Gli otto siti senza dati grouped restano unavailable nelle heatmap, rappresentati in grigio; un valore mancante non viene imputato come attribuzione nulla. RF e valutazione predittiva continuano a includere tutti i 100 siti.

La copertura è non uniforme: 87 siti FOLD sono presenti in tre explanation-run e cinque in una sola, ossia `adobe.com`, `bing.com`, `facebook.com`, `google.com` e `indeed.com`. Anche ciascun sito RF compare in tre explanation-run. Le cinque training run sono rappresentate globalmente, ma ogni sito non ha cinque spiegazioni su modelli diversi. Le numerosità qui riportate derivano dai record effettivi e da `coverage.csv`, non dalle quote del protocollo completo originario.

Tabella 6: Cohort FAST per configurazione. Le osservazioni sommano i sample-run assegnati attraverso le cinque run; le reference sono selezionate dal training della run.

Analisi	Osservazioni	Tracce distinte	Siti	Reference
RF multiclass	300	300	100	32
FOLD multiclass	266	266	92	4
FOLD binary monitored	266	266	92	2 + 2 miste
FOLD binary background	266	263–265	–	2 + 2 miste

Nella binary, per ogni rapporto vengono spiegate 266 osservazioni background oltre alle 266 monitored. Le tracce background distinte sono rispettivamente 264, 265, 263, 264 e 263 ai rapporti 0.30–0.70: alcune ricompaiono in run diverse. Il background è aggregato come un'unica popolazione, non come 100 siti. La selezione cerca campioni test comuni ai rapporti entro ciascuna run quando l'intersezione è disponibile; altrimenti usa il test del rapporto. Le reference binary sono selezionate per essere comuni ai rapporti entro la run. Non viene assunto un cohort background identico tra tutte le run o un confronto paired tra rapporti diversi.

7.4 Aggregazione e intervalli di confidenza

Una media diretta di tutti i record darebbe più peso ai siti con più osservazioni. Per le XAI vengono invece mediate prima le osservazioni nello stesso site/run, poi le repetition disponibili per quel sito, infine i siti con peso uguale. Per il gruppo g, indicando con R_s le run osservate del sito s e con X_{sr} il relativo insieme di campioni, l'estimand principale è

$$A_g = \frac{1}{|\mathcal{S}|} \sum_{s \in \mathcal{S}} \frac{1}{|R_s|} \sum_{r \in R_s} \frac{1}{|X_{sr}|} \sum_{x \in X_{sr}} |\phi_g^{(r)}(x)|. \tag{2}$$

Lo stesso ordine di aggregazione viene usato per probabilità e contributi con segno. Il termine all-sites nei grafici indica tutti i siti del cohort pertinente: 100 per RF, 92 per grouped FOLD. Le magnitudini RF e FOLD non sono direttamente confrontabili, perché cambiano modello, unità di attribuzione, reference e cohort.

Le sole medie non mostrano quanto una stima sia stabile rispetto ai campioni osservati. Per le XAI sono quindi riportati CI al 95% mediante percentile bootstrap, con 10.000 draw e seed 20261008. Si ricampionano i siti e le osservazioni all'interno delle celle site/run disponibili;

per ciascun sito si mantiene la media delle sue run osservate. I modelli addestrati rimangono fissi e le celle mancanti non vengono sintetizzate. Nel pannello Instagram manca il livello di ricampionamento dei siti; il background binary è trattato come un'unica popolazione.

Il CI XAI quantifica così l'incertezza dell'aggregazione condizionata ai modelli osservati, non la variabilità di nuovi training indipendenti. Inoltre un CI al 95% della media non significa che contenga il 95% dei singoli valori SHAP. Con poche osservazioni per sito e spesso una sola per cella, il bootstrap entro cella può essere degenere: intervalli stretti non certificano stabilità rispetto a tracce non osservate.

Per le performance si calcola invece la media dei cinque valori ottenuti sui test set completi e il CI percentile al 95% ricampionando i cinque valori run-level, sempre con 10.000 draw e lo stesso seed. Questi intervalli descrivono la variabilità tra le run disponibili e vanno distinti dall'incertezza XAI.

7.5 Dominant group, heatmap e delta paired

7.5.1 Gruppo dominante e heatmap

Una magnitudine globale elevata potrebbe essere guidata da pochi siti. Per verificarne la diffusione viene identificato, per ciascun sito, il gruppo con il maggiore mean $|\phi|$ dopo la media delle run disponibili. Ogni sito viene contato una sola volta: il risultato non è una votazione dei vincitori delle singole run. La distribuzione dei gruppi dominanti è una statistica descrittiva; i grafici disponibili non riportano CI.

La heatmap conserva invece i quattro valori di ciascun sito. Permette di osservare eterogeneità, dominanze diverse e variazioni site-specific che la media globale comprime. Le righe seguono un ordine deterministico dei 100 siti, le colonne sono G1–G4 e il colore rappresenta il mean $|\phi|$ dopo l'aggregazione entro sito. Gli otto siti senza tracce eleggibili sono grigi. Le heatmap delle configurazioni usano una scala cromatica comune, così da rendere confrontabili le magnitudini.

7.5.2 Delta paired rispetto alla baseline

Il valore assoluto in una configurazione non indica direttamente quanto il comportamento sia cambiato rispetto al modello senza defense e background. Per questo viene calcolato il delta della formula 3:

$$\Delta_g = A_g^{\text{configurazione}} - A_g^{\text{baseline}}. \tag{3}$$

Un delta negativo indica una minore magnitudine del contributo del gruppo, uno positivo una maggiore magnitudine e zero nessuna variazione dell'estimand. Non si tratta di una quota normalizzata di importanza né di una differenza tra contributi con segno.

Il confronto è paired sulle stesse osservazioni: run, sito, sample ID, modello, cohort, output e dimensione devono corrispondere esattamente. Si calcola prima $|\phi_g^{\text{configurazione}}(x)| - |\phi_g^{\text{baseline}}(x)|$, poi si applica l'aggregazione della formula 2 e il bootstrap alle differenze paired. Non si sottraggono due CI marginali indipendenti. `pairing.csv` conferma il matching completo per tutte le 25 configurazioni nonbaseline, sia RF sia FOLD multiclass. I delta discussi riguardano l'output multiclass; non esiste un confronto binary con una baseline closed-world.

7.6 Baseline multi-sito

7.6.1 Performance

Nella baseline entrambi i modelli raggiungono performance elevate sui test completi. Le medie delle cinque training run e i CI sono riportati nella Tabella 7. FOLD presenta medie leggermente maggiori di RF, ma gli intervalli marginali si sovrappongono: il confronto descrittivo non costituisce un test di superiorità statistica.

Tabella 7: Baseline closed-world: media e CI al 95% dei cinque valori run-level, calcolati sui test set completi.

Modello	Accuracy [CI 95%]	Macro-F1 [CI 95%]
RF	0.9831 [0.9791, 0.9865]	0.9826 [0.9794, 0.9860]
FOLD	0.9867 [0.9831, 0.9898]	0.9860 [0.9835, 0.9885]

7.6.2 TreeSHAP RF

La Figura 9 mostra le feature principali per la probabilità del sito reale. Nel pannello all-sites, relativo ai 100 siti, le tre magnitudini medie maggiori sono la deviazione standard delle dimensioni dei pacchetti (0.0391, CI [0.0364, 0.0418]), la dimensione media (0.0363, CI [0.0329, 0.0399]) e la dimensione media delle risposte del target (0.0339, CI [0.0307, 0.0373]). Le statistiche dimensionali occupano quindi posizioni rilevanti anche nel cohort multi-sito; le feature mostrate sono le prime 15 per ciascun pannello, senza una barra che sommi le rimanenti.

Le barre rappresentano mean |SHAP| in unità di probabilità, mentre le barre di errore mostrano il CI della media aggregata. Il pannello Instagram è un sottoinsieme della nuova campagna, utile a leggere un caso specifico; non sostituisce il risultato primario su 100 siti.

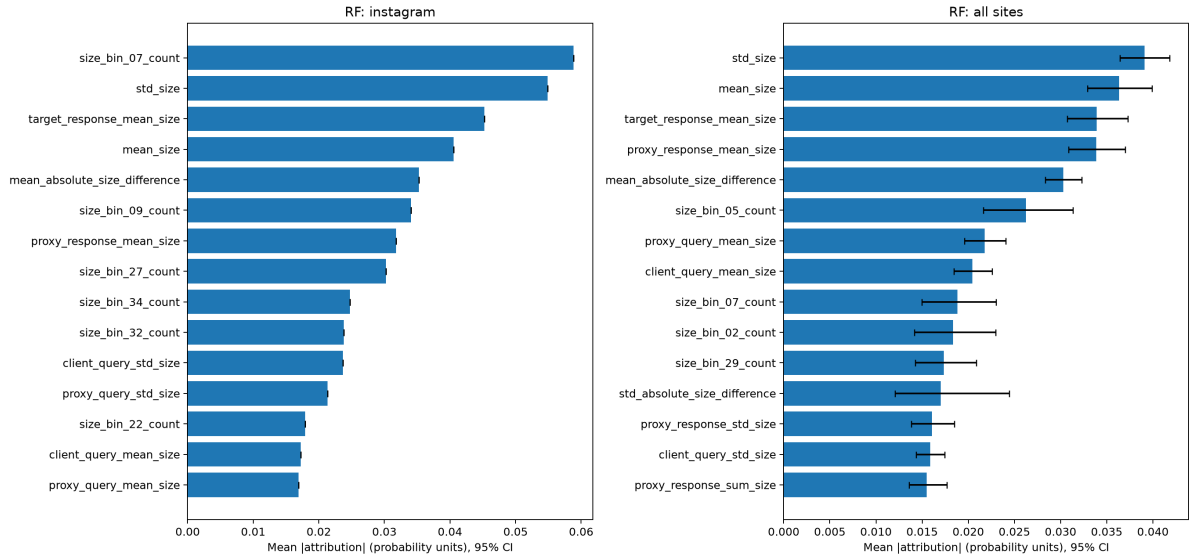


Figura 9: TreeSHAP RF nella baseline FAST: prime 15 feature ordinate separatamente per Instagram (sinistra) e per tutti i 100 siti (destra, risultato primario). Target dinamico pari al sito reale; cohort globale di 300 tracce distinte e 32 reference di training per run. Barre: mean |SHAP|; errori: CI al 95% condizionati ai modelli osservati.

7.6.3 Grouped Shapley FOLD

Nello studio Instagram della Figura 2 G1 aveva già la maggiore magnitudine media. Nel cohort primario di 92 siti, G1 presenta nettamente la maggiore magnitudine media: 0.3379, rispetto a 0.1793 per G2, 0.1520 per G3 e 0.1550 per G4. La Tabella 8 riporta i CI e la probabilità media del sito reale, pari a 0.8330. La Figura 10 affianca il sottoinsieme Instagram al risultato all-sites; tutte le statistiche principali si riferiscono alle 266 tracce eleggibili, con peso uguale ai siti.

7.6.4 Diffusione della dominanza di G1

La distribuzione nella Figura 11 mostra che G1 è dominante in 84 dei 92 siti (91.3%); G2 in cinque, G3 in due e G4 in uno. La maggiore magnitudine globale di G1 è quindi un comportamento

Tabella 8: Baseline grouped FOLD: magnitudini G1–G4 e probabilità del sito reale, aggregate sui 92 siti eleggibili. CI al 95% condizionati ai modelli osservati.

Quantità	Media	CI 95%
G1	0.3379	[0.3163, 0.3583]
G2	0.1793	[0.1675, 0.1906]
G3	0.1520	[0.1422, 0.1615]
G4	0.1550	[0.1449, 0.1650]
P(sito reale)	0.8330	[0.7948, 0.8632]

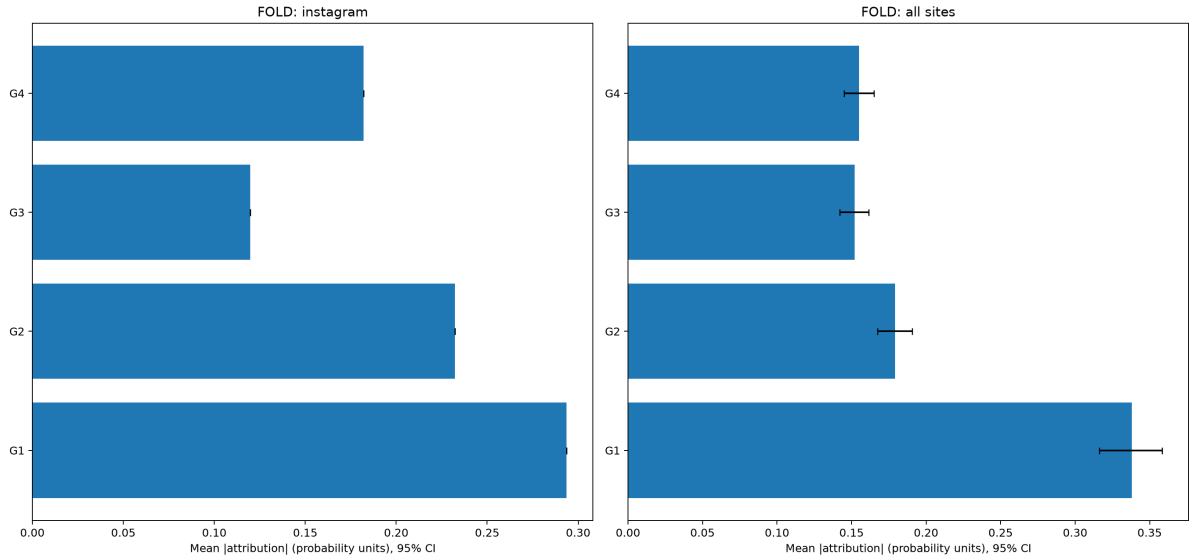


Figura 10: Grouped Shapley FOLD nella baseline FAST: Instagram a sinistra come esempio secondario, all-sites a destra come risultato primario sui 92 siti eleggibili. Il cohort comprende 266 tracce distinte, quattro gruppi di risoluzioni e quattro reference di training per run. Barre: mean $|\phi_g|$; errori: CI al 95% della media aggregata.

diffuso nel cohort, non soltanto una media guidata da pochi siti. La heatmap della Figura 12 mantiene visibili le differenze tra siti e le otto righe unavailable. Questi risultati descrivono il modello rispetto alle reference scelte e non dimostrano un ruolo causale della parte iniziale del traffico.

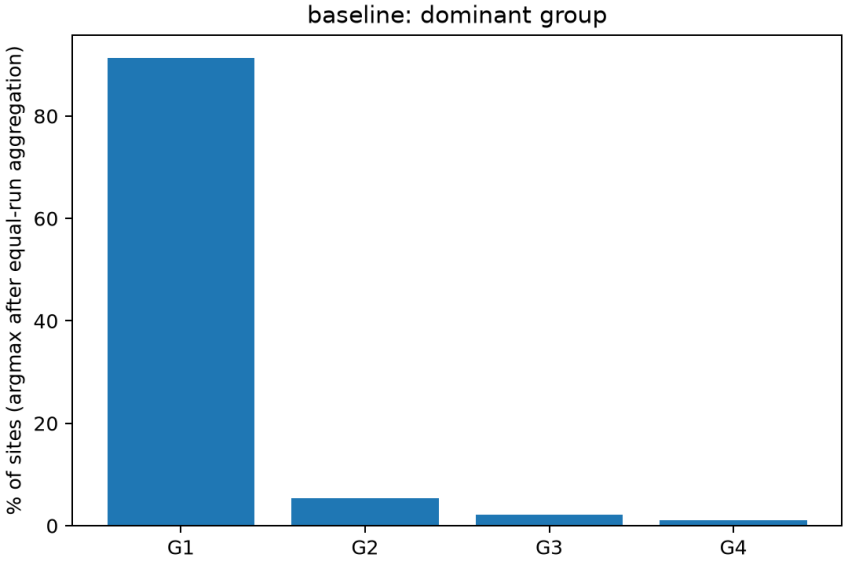


Figura 11: Gruppo dominante nella baseline: argmax del mean $|\phi|$ di ciascun sito dopo la media delle run disponibili. Conteggi G1–G4: 84, 5, 2 e 1 su 92 siti; ogni sito è contato una sola volta. Le percentuali sono statistiche descrittive, senza CI.

7.7 Risultati cross-run con defense

7.7.1 Performance sui cinque run

Le defense producono effetti diversi sulle performance complete e sulle spiegazioni del cohort FAST. Le Figure 13 e 14 riportano le medie e i CI di FOLD per tutte le configurazioni, includendo anche baseline e open-world. Le Tabelle 14 e 15 in appendice riportano baseline e tutte le 20 defense per entrambi i modelli.

Il padding riduce progressivamente l'accuracy media FOLD da 0.9811 a intensità 0.10 fino a 0.5927 a 1.00 (CI [0.5814, 0.6076]); a quest'ultima intensità la macro-F1 è 0.5746 (CI [0.5652, 0.5892]). Dummy mantiene accuracy tra 0.9808 e 0.9865. Fragmentation presenta una degradazione più moderata: l'accuracy è 0.9379 a 0.70 e 0.9439 a 1.00. Combined raggiunge 0.5441 a 0.70 (CI [0.5168, 0.5715]) e risale a 0.7365 a 1.00 (CI [0.7278, 0.7467]). Quest'ultimo recupero è presente nella media cross-run; non va interpretato come un andamento generale monotono dell'efficacia della defense.

7.7.2 Attribuzioni, probabilità e delta

Le Figure 15 e 16 mostrano magnitudini e delta paired dei gruppi per tutte le famiglie. Il pannello all-sites, a destra, rappresenta i 92 siti eleggibili; quello Instagram resta un esempio secondario. La Tabella 16 in appendice riporta le medie dei gruppi e la true-site probability. Quest'ultima riguarda il sottoinsieme spiegato e non coincide con l'accuracy sull'intero test.

Padding. G1 mantiene la magnitudine media maggiore, ma diminuisce da 0.3379 nella baseline a 0.1446 a intensità 1.00; G2–G4 valgono 0.1131, 0.1219 e 0.1129. Alle intensità intermedie G3 e G4 possono aumentare rispetto alla baseline, mentre a 1.00 tutti i delta sono negativi. Per G1 il delta è -0.1934 (CI $[-0.2120, -0.1746]$). La probabilità media del sito reale passa da

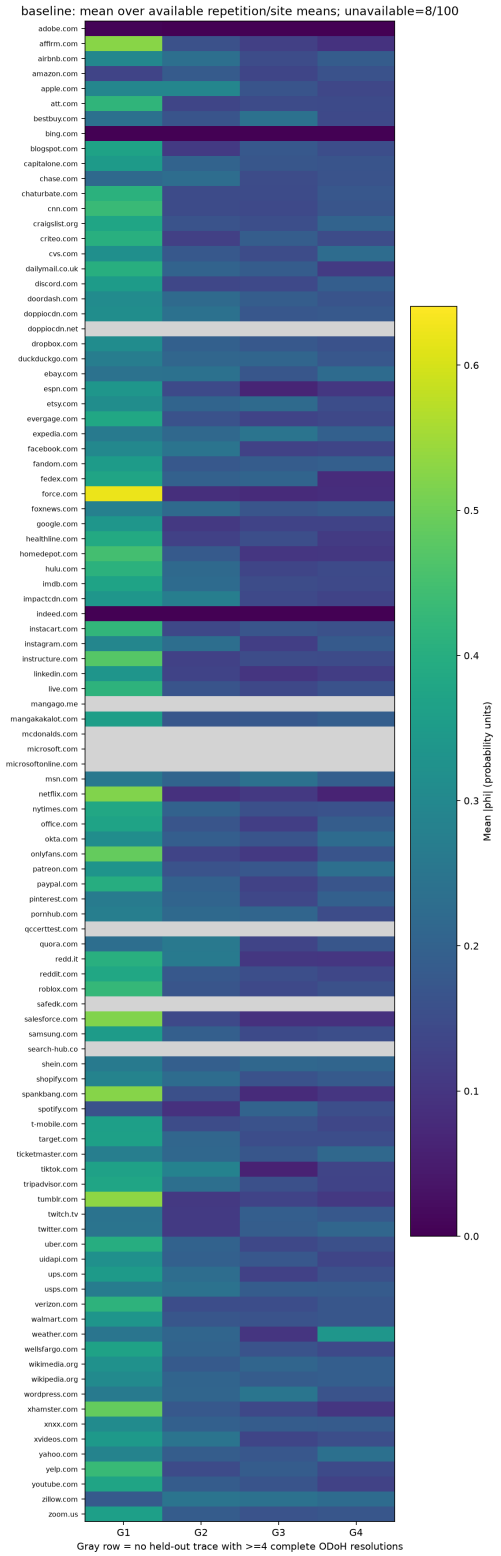


Figura 12: Heatmap baseline FOLD: righe = 100 siti in ordine deterministico; colonne = G1–G4; colore = mean $|\phi|$ dopo la media delle run disponibili per sito. Le 92 righe misurate costituiscono il cohort primario; le otto righe grigie indicano nessuna traccia held-out con almeno quattro risoluzioni complete, non SHAP uguale a zero. La scala cromatica è comune alle configurazioni.

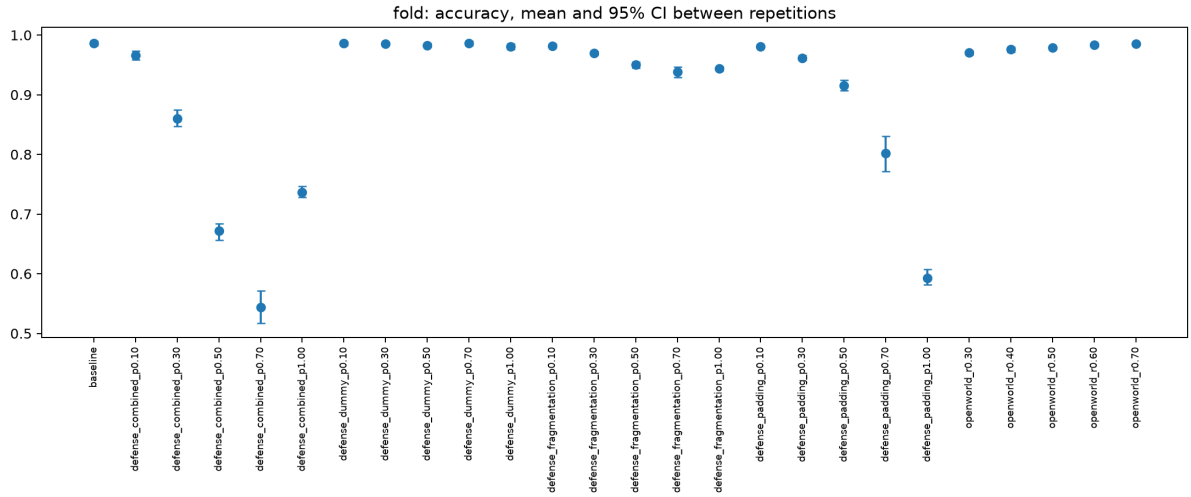


Figura 13: Accuracy FOLD sui test set completi: media di cinque training run per ciascuna delle 26 configurazioni e CI percentile al 95% ottenuto ricampionando i valori run-level. La copertura XAI di 92 siti non restringe la valutazione predittiva.

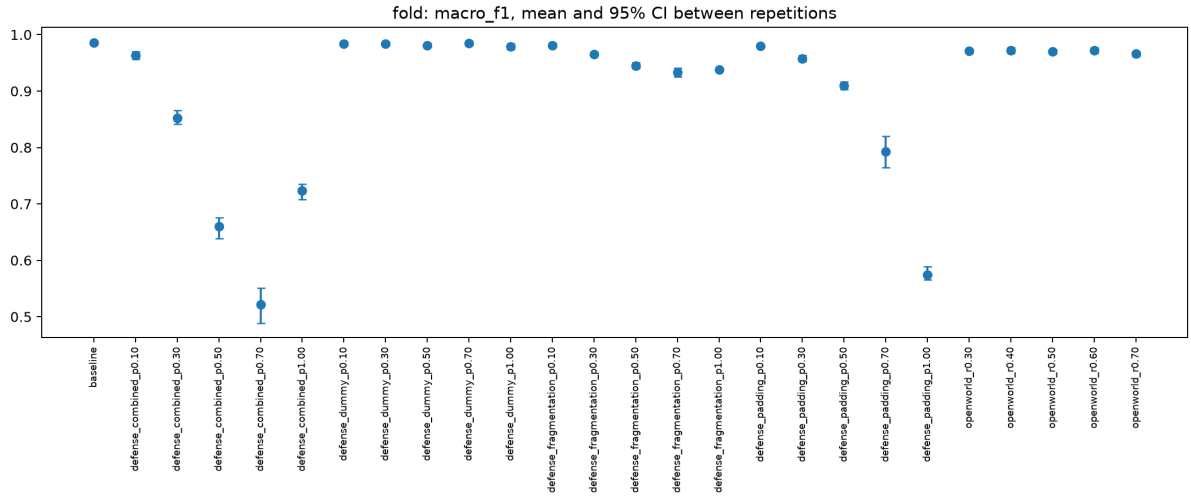


Figura 14: Macro-F1 FOLD delle classi monitored: media e CI al 95% sui cinque valori run-level per configurazione. Nell'open-world il background contribuisce come negativo ma non come classe nella media.

0.8330 a 0.4906 (CI [0.4287, 0.5530]); a 0.10 è invece 0.8465. La riduzione delle performance si accompagna quindi a minori magnitudini alle intensità più alte, ma non a un calo uniforme di tutti i gruppi a ogni intensità.

Dummy. Le attribuzioni rimangono vicine alla baseline e G1 conserva la maggiore magnitudine media a tutte le intensità. A 1.00 G1 vale 0.3054, con delta −0.0325 (CI [−0.0472, −0.0171]); G2–G4 valgono 0.1844, 0.1704 e 0.1720. La probabilità media del sito reale varia tra 0.8267 e 0.8415. Le performance elevate convivono quindi con piccoli cambiamenti nella distribuzione dei contributi, senza un andamento monotono della probabilità.

Fragmentation. G1 resta il gruppo con la magnitudine globale maggiore, ma alle intensità intermedie si riduce la distanza dagli altri gruppi. A 0.50 G1 scende a 0.2643, mentre G3 e G4 salgono a 0.1802 e 0.1827; i loro delta sono 0.0282 e 0.0277, con CI interamente positivi. A 1.00 G1 risale a 0.3117 e G2–G4 valgono 0.1605, 0.1573 e 0.1577. La probabilità media del sito reale è 0.7953 a 1.00, rispetto a 0.8330 nella baseline. La degradazione delle performance non corrisponde quindi a una diminuzione proporzionale di tutti i contributi.

Combined. Alle intensità basse e intermedie la distribuzione cambia: a 0.30 G1 e G2 hanno delta negativi, mentre G3 e G4 positivi. G1 mantiene comunque la maggiore magnitudine globale alle cinque intensità. A 0.70 tutti i gruppi sono sotto la baseline: G1 vale 0.1318 e il suo delta è −0.2061 (CI [−0.2268, −0.1849]); la probabilità del sito reale è 0.4336. A 1.00 probabilità e attribuzioni recuperano, rispettivamente a 0.6248 e 0.2071 per G1, ma rimangono inferiori alla baseline. Il delta rende espliciti sia la redistribuzione iniziale sia la contrazione alle intensità maggiori.

Per ogni configurazione defense sono disponibili nel repository anche dominant-group chart e heatmap site×group; i grafici di probabilità completano quelli di magnitudine e delta. Questo insieme supplementare permette di verificare se le variazioni globali si concentrino su siti specifici, senza inserire tutte le figure nel corpo del report.

7.8 Risultati cross-run open-world

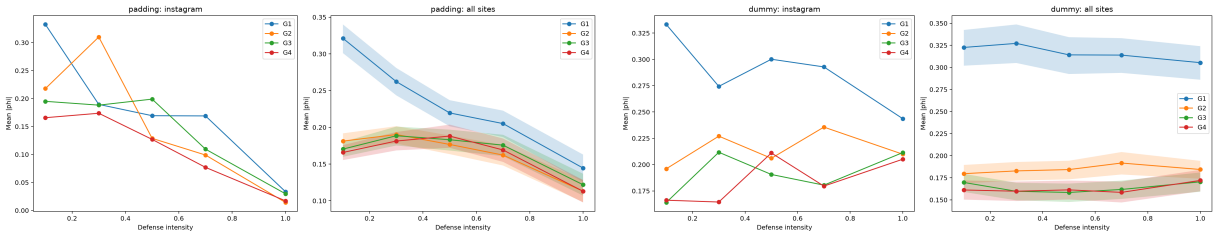
7.8.1 Performance e detection

L'open-world richiede di distinguere identificazione del sito e riconoscimento monitored/background. La Tabella 9 riporta accuracy e macro-F1 FOLD ai cinque rapporti; i risultati completi di RF e FOLD sono nella Tabella 17 in appendice. L'accuracy media FOLD aumenta da 0.9704 a 0.9850, mentre la macro-F1 rimane tra 0.9660 e 0.9724. L'accuracy include il background e cambia anche la composizione del test: il suo aumento non dimostra un miglioramento uniforme dell'identificazione dei siti monitored.

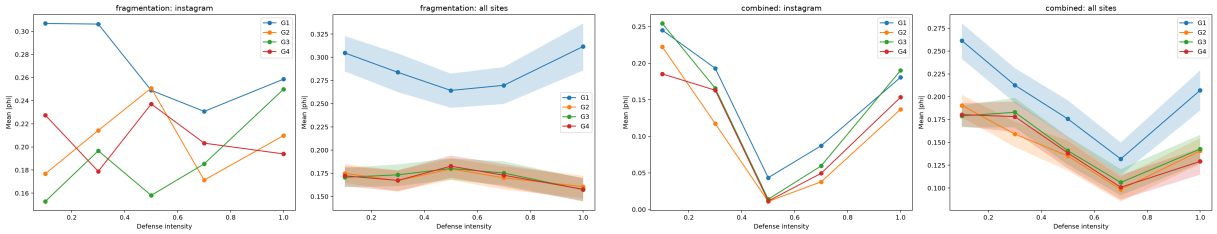
Tabella 9: Open-world FOLD: media e CI al 95% sui cinque test completi per rapporto di background.

Background	Accuracy [CI 95%]	Macro-F1 [CI 95%]
0.30	0.9704 [0.9670, 0.9737]	0.9708 [0.9682, 0.9742]
0.40	0.9758 [0.9719, 0.9797]	0.9724 [0.9677, 0.9771]
0.50	0.9787 [0.9764, 0.9810]	0.9703 [0.9666, 0.9739]
0.60	0.9834 [0.9806, 0.9862]	0.9721 [0.9674, 0.9766]
0.70	0.9850 [0.9833, 0.9866]	0.9660 [0.9618, 0.9696]

Nelle medie osservate FOLD ha accuracy, TPR e AUC maggiori di RF a tutti i rapporti. La macro-F1 è maggiore a 0.40–0.70 e inferiore a 0.30. Il FPR di detection FOLD è maggiore a 0.30 e 0.40, ma minore a 0.50–0.70. A 0.30 il TPR è 0.9893 (CI [0.9834, 0.9955]) e il FPR 0.0447 (CI

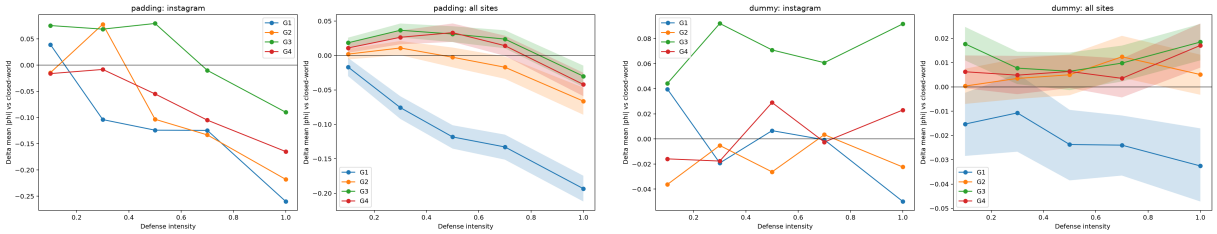


(a) Padding. **(b)** Dummy.

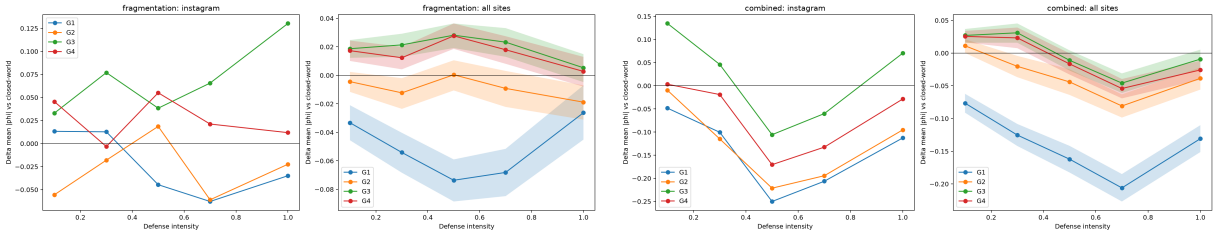


(c) Fragmentation. **(d)** Combined.

Figura 15: Magnitudini grouped FOLD nelle quattro defense: mean $|\phi_g|$ in funzione dell'intensità, con CI XAI al 95% (bande). In ciascun pannello Instagram è a sinistra, il cohort primario di 92 siti e 266 osservazioni a destra. Le scale dei pannelli possono differire; la baseline è riportata separatamente nella Figura 10.



(a) Padding. **(b)** Dummy.



(c) Fragmentation. **(d)** Combined.

Figura 16: Delta paired di mean $|\phi_g|$ rispetto alla baseline closed-world per le quattro defense; bande = CI al 95% delle differenze paired. In ciascun pannello Instagram è a sinistra e i 92 siti eleggibili a destra. La linea zero indica nessuna variazione della magnitudine aggregata, non un contributo SHAP nullo.

[0.0342, 0.0533]); a 0.70 sono 0.9867 e 0.0096. Questi confronti sono descrittivi e non test di superiorità tra modelli. Le Figure 17 e 18 mostrano detection FPR e AUC con la loro variabilità cross-run; le Tabelle 18 e 19 riportano anche i TPR.

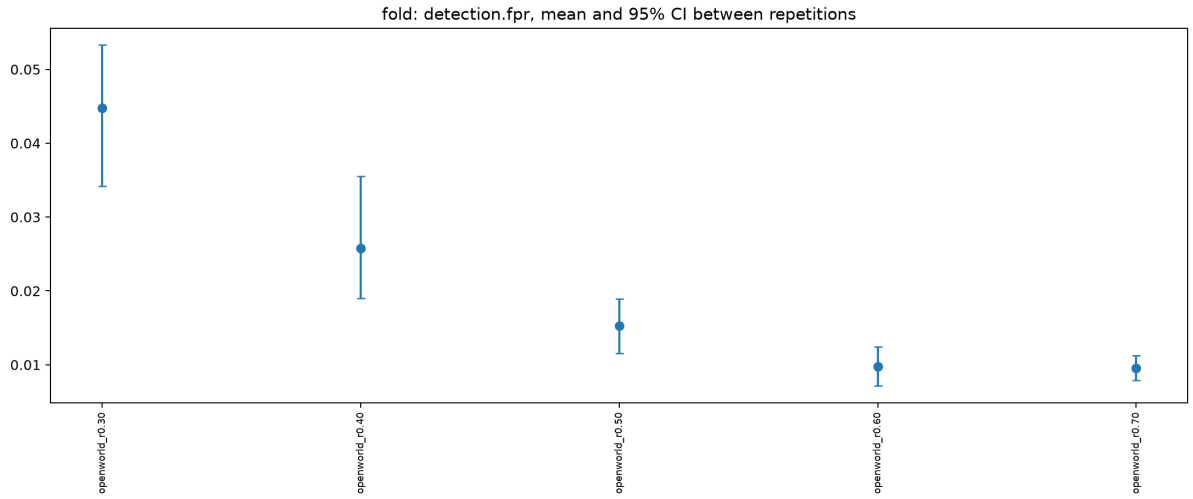


Figura 17: FPR di detection FOLD nei cinque rapporti open-world: quota di background classificato monitored con soglia > 0.5. Punti e barre rappresentano media e CI al 95% sui cinque valori run-level, calcolati sui test completi.

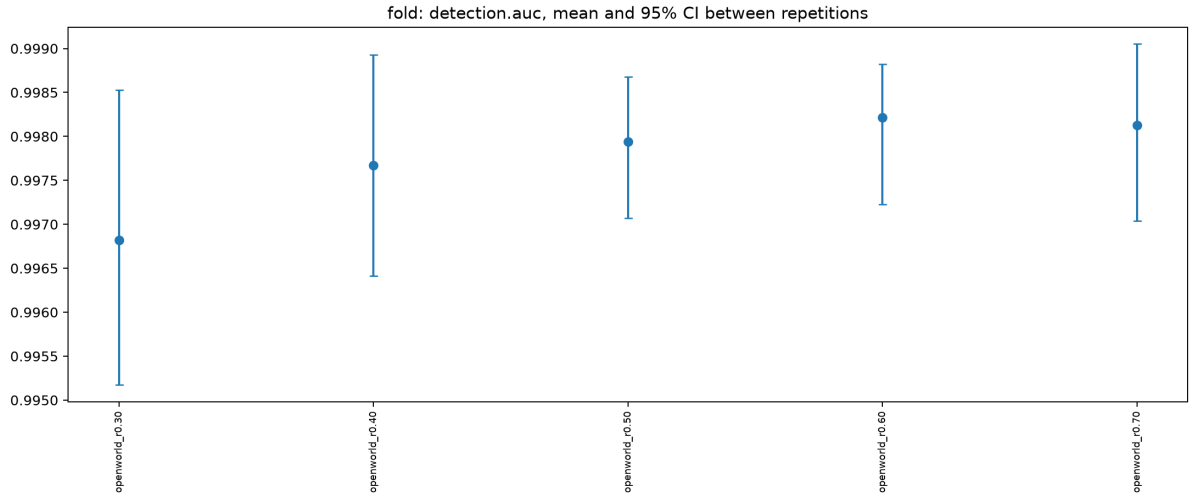


Figura 18: ROC AUC FOLD per la detection monitored/background nei cinque rapporti: media e CI al 95% sui cinque training run. La AUC riassume tutte le soglie e riguarda un problema distinto dall'identificazione del sito.

7.8.2 Spiegazioni multiclass

Le spiegazioni multiclass riguardano P_{FOLD}(sito reale), non sempre Instagram, sulle stesse 266 tracce dei 92 siti eleggibili. G1 mantiene la maggiore magnitudine globale a tutti i rapporti: i valori sono compresi tra 0.2796 e 0.2962. G2–G4 restano più bassi, con differenze che non seguono tutte un andamento monotono (Figura 19; Tabella 20 in appendice).

Il delta rispetto alla baseline è negativo per G1 a tutti i rapporti, da -0.0417 a -0.0583, con CI interamente sotto zero. Gli altri gruppi cambiano meno: per esempio G4 aumenta a 0.30 e 0.50, mentre a 0.70 il suo CI del delta comprende zero (Figura 20). La probabilità media del sito reale diminuisce da 0.8000 a 0.7554 tra 0.30 e 0.70, rispetto a 0.8330 nella baseline (Figura 21).

Questo comportamento del cohort spiegato va letto separatamente dall'accuracy complessiva, che include una quota crescente di background.

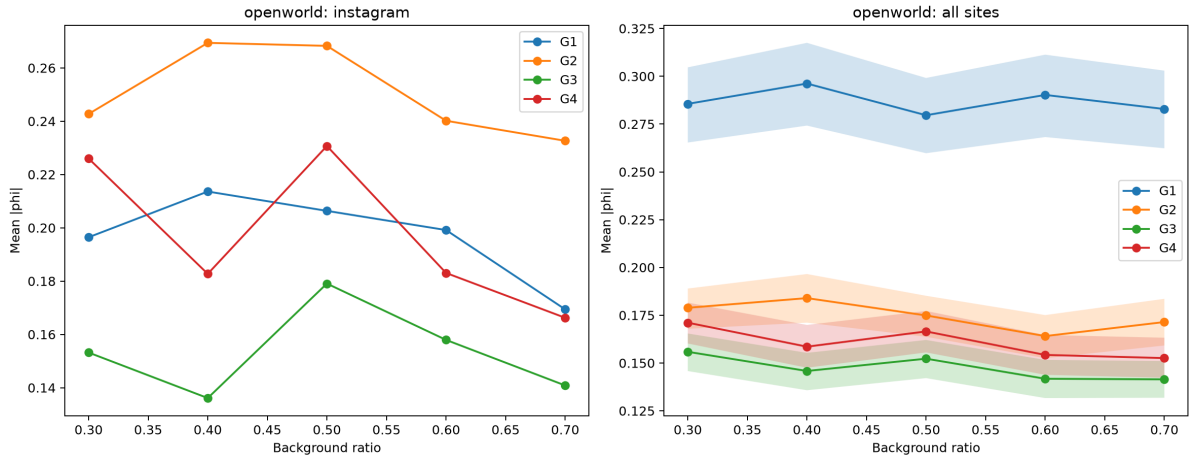


Figura 19: Open-world multiclass: mean $|\phi_g|$ per P(sito reale) ai cinque rapporti di background, con CI XAI al 95%. Instagram a sinistra; cohort primario di 92 siti e 266 tracce a destra. Quattro reference monitored di training per run.

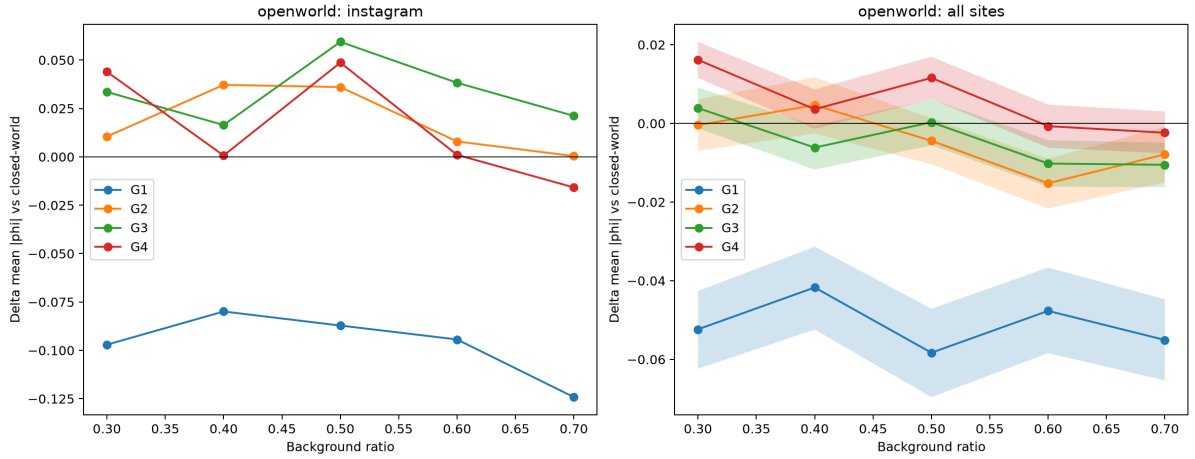


Figura 20: Delta multiclass paired rispetto alla baseline closed-world, sulle stesse osservazioni e dimensioni. Bande: CI al 95% delle differenze di magnitudine. Instagram a sinistra e 92 siti eleggibili a destra; la linea zero indica nessuna variazione aggregata.

7.8.3 Spiegazioni binary

La binary spiega P(monitored) sui due cohort, usando due reference monitored e due background. La Figura 22 descrive le magnitudini; la Figura 23 ne distingue la direzione. Il valore assoluto evita la cancellazione tra contributi opposti, mentre il segno mostra se un gruppo aumenta o diminuisce la probabilità monitored rispetto al riferimento.

Nel primo cohort monitored, centrato su Instagram, G2 aveva la maggiore magnitudine binary (Figura 8). Nel nuovo cohort monitored multi-sito è invece G1 a prevalere: il passaggio cambia siti, campioni, reference e modelli aggregati, quindi questa differenza descrive i due disegni sperimentali e non invalida il primo risultato. Nel cohort monitored i quattro contributi medi con segno sono positivi a tutti i rapporti, e G1 ha la maggiore magnitudine media, compresa tra 0.2746 e 0.3061. La probabilità media monitored è compresa tra 0.9823 e 0.9993. Nel cohort background i quattro contributi medi sono negativi e G1 ha ancora la maggiore magnitudine, tra 0.2428 e 0.3187; la probabilità monitored è compresa tra 0.0067 e 0.0332. I segni medi opposti

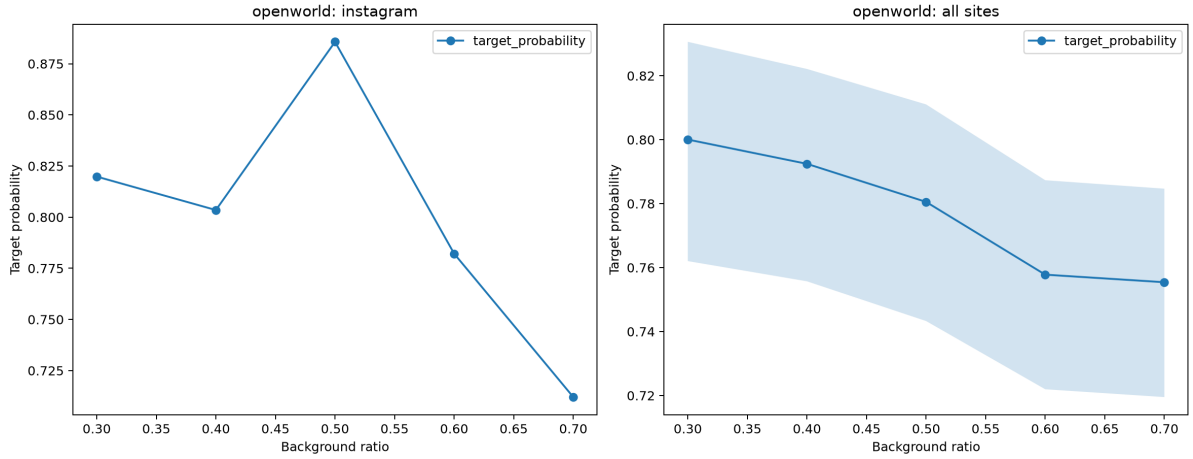


Figura 21: Probabilità media del sito reale nel cohort multiclass open-world, con CI XAI al 95%. Instagram a sinistra e 92 siti eleggibili a destra. La media è calcolata entro site/run e poi con peso uguale ai siti; non è l'accuracy sul test completo.

rendono leggibile la distinzione tra le popolazioni, ma non implicano che ogni singola attribuzione abbia lo stesso segno. Le Tabelle 21 e 22 in appendice riportano probabilità, magnitudini e medie con segno.

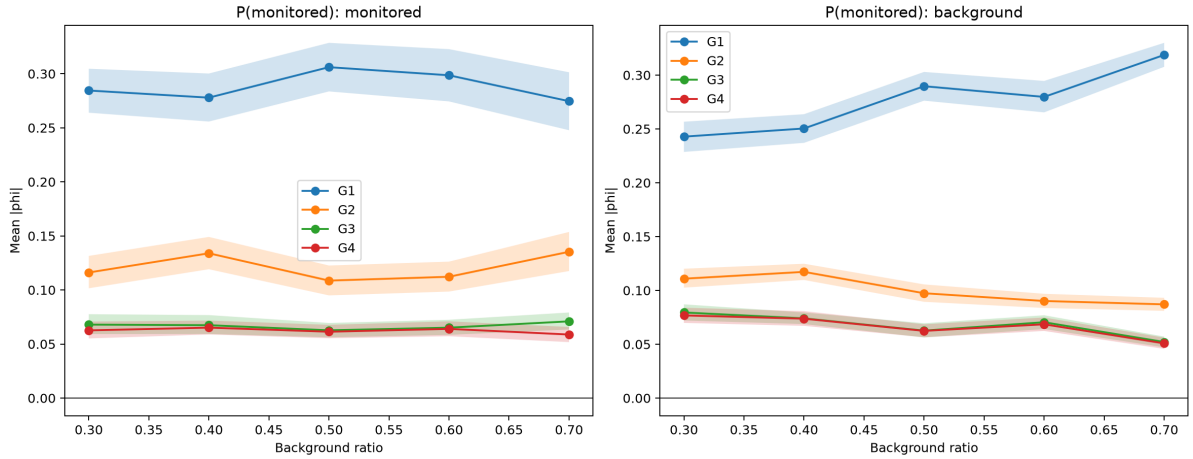


Figura 22: Binary FOLD: mean $|\phi_g|$ per $P(\text{monitored})$ ai cinque rapporti, con CI XAI al 95%. A sinistra 266 osservazioni monitored sui 92 siti eleggibili; a destra 266 osservazioni background per rapporto, aggregate come un'unica popolazione. Reference miste: due monitored e due background per run.

7.9 Sintesi e confronto con lo studio iniziale

La prima fase aveva individuato G1 come gruppo di maggiore mean $|\phi|$ nella baseline Instagram. La seconda mostra che questa osservazione non è limitata a quel cohort: G1 ha la maggiore magnitudine globale ed è dominante in 84 dei 92 siti eleggibili. Anche le statistiche dimensionali principali della RF restano rilevanti nel risultato su 100 siti. Heatmap e dominant-group analysis rendono visibile la diffusione di questi comportamenti, insieme alle differenze tra siti.

Le defense conservano alcune tendenze generali: padding e combined degradano maggiormente le performance, dummy ha un impatto minore e fragmentation più moderato. Il recupero combined a intensità 1.00 appare sia nella run iniziale sia nella media delle cinque run. Le attribuzioni, invece, non devono coincidere numericamente: nella seconda fase la probabilità spiegata è quella del sito reale di ciascuna osservazione e cambiano cohort e reference. I delta paired quantificano le variazioni entro questo nuovo disegno.

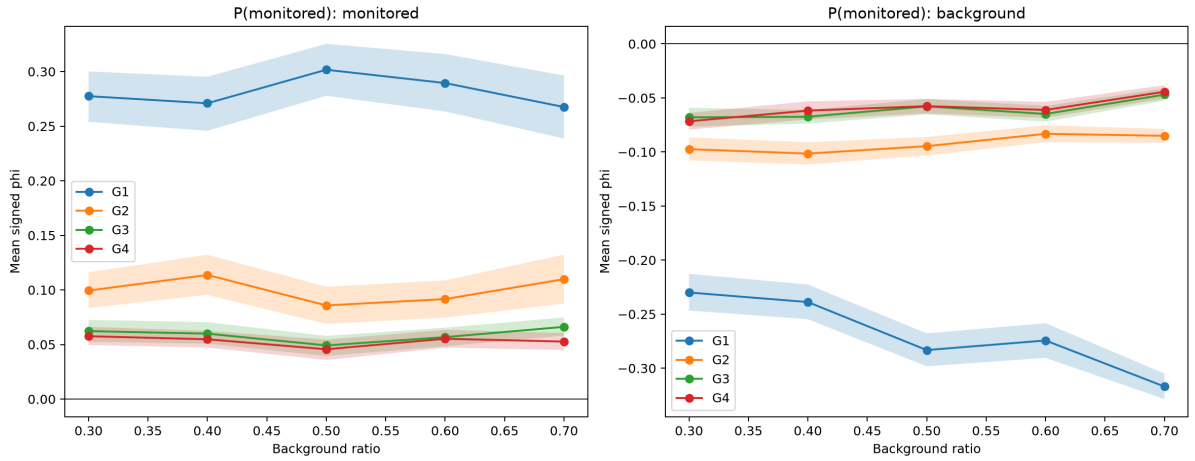


Figura 23: Binary FOLD: contributi medi con segno a $P(\text{monitored})$, con CI XAI al 95%. Cohort monitored a sinistra e background a destra. Valori positivi aumentano la probabilità monitored rispetto alle reference, valori negativi la diminuiscono; il segno della media non vincola ogni contributo individuale.

Nell'open-world multiclass e nella binary monitored, G1 ha la maggiore magnitudine globale ai rapporti analizzati; nel piccolo cohort originale G2 poteva superare G1 e prevaleva nella binary monitored. La differenza evidenzia perché un caso locale e un'aggregazione multi-sito siano complementari. Restano coerenti le direzioni medie binary, positive per monitored e negative per background, senza imporre il segno di ogni attribuzione individuale. L'estensione amplia quindi l'evidenza entro i suoi limiti di copertura e campionamento, senza trasformarla in una conclusione causale o in una garanzia su siti non osservati.

8 Limitazioni

Le prime limitazioni riguardano lo studio iniziale presentato nelle Sezioni 3–6.

Per ogni configurazione è stata eseguita una sola ripetizione.I risultati non permettono quindi di valutare quanto le performance e le spiegazioni cambino ripetendo l'addestramento.

Le spiegazioni grouped dipendono dalle reference scelte. Con reference diverse potrebbero cambiare il riferimento di confronto e i contributi dei gruppi.

L'analisi multiclass dettagliata riguarda il cohort Instagram selezionato. Le osservazioni su questi campioni non possono essere estese automaticamente agli altri siti.

Nell'analisi binary i campioni background non sono gli stessi in tutti i rapporti. Le differenze osservate risentono quindi anche dei diversi insiemi di tracce spiegate.

La campagna cross-run usa il protocollo FAST, con meno osservazioni e reference rispetto al protocollo completo originariamente previsto.

Grouped FOLD copre 92 siti su 100: gli altri otto non dispongono di tracce held-out con almeno quattro risoluzioni complete. La copertura è inoltre non uniforme tra le repetition.

I CI delle attribuzioni descrivono l'incertezza dell'aggregazione sui modelli osservati, non la variabilità di nuovi retraining indipendenti.

9 Conclusioni

Ho implementato una pipeline riproducibile per spiegare sia la Random Forest attraverso le sue feature sia FOLD attraverso gruppi di risoluzioni. Il predictor end-to-end ricostruisce dalla stessa traccia perturbata le rappresentazioni e le probabilità RF, mantenendo coerenti tutti gli input della decisione finale. Lo studio dettagliato iniziale su Instagram ha permesso di validare il metodo e analizzare baseline, defense e open-world, distinguendo output multiclass e binary.

Ho poi esteso lo studio a cinque training run per ciascuna delle 26 configurazioni, con target dinamico pari al sito reale. Nella baseline multi-sito G1 presenta la maggiore magnitudine globale ed è dominante in 84 dei 92 siti eleggibili: l'osservazione iniziale su Instagram trova quindi riscontro in un insieme più ampio. Dominant-group analysis e heatmap mostrano quanto il comportamento sia diffuso e quale eterogeneità rimanga tra siti.

Le defense modificano diversamente attribuzioni e performance; il delta paired misura direttamente la variazione di magnitudine rispetto alla baseline nello stesso disegno sperimentale. Il recupero combined a intensità 1.00 è osservato anche nella media cross-run. Nell'open-world è necessario distinguere la probabilità del sito reale dalla detection monitored/background; il confronto con il primo cohort mostra inoltre che le gerarchie dei gruppi possono cambiare nell'aggregazione multi-sito.

I CI quantificano l'incertezza delle stime entro i limiti dei due bootstrap. Il protocollo FAST rende praticabile la explainability senza abbreviare il training né cambiare i modelli. La copertura grouped di 92/100 siti è dichiarata esplicitamente e gli otto siti unavailable non sono imputati: il significato strutturale di G1–G4 resta invariato. Le due fasi forniscono evidenza complementare sul comportamento dei modelli rispetto alle reference e non un'interpretazione causale del traffico.

A Tabelle complete delle attribuzioni

Le tabelle seguenti riportano le attribuzioni per tutte le configurazioni defense e open-world. Le Tabelle 10 e 11 riguardano l'output multiclass; le Tabelle 12 e 13 distinguono magnitudine e segno dei contributi binary. Probabilità e contributi sono arrotondati a quattro decimali.

Tabella 10: Risultati multiclass completi della baseline e delle defense sulle stesse 15 tracce Instagram. $\overline{P}_8$ è la probabilità media Instagram; G1–G4 riportano i contributi medi assoluti.

Defense	Intensità	$\overline{P}_8$	G1	G2	G3	G4
Baseline	0.00	0.8451	0.2950	0.2146	0.1654	0.1687
Padding	0.10	0.9250	0.2829	0.2136	0.2169	0.2103
Padding	0.30	0.8659	0.2741	0.2451	0.1685	0.1770
Padding	0.50	0.5052	0.1434	0.1247	0.1383	0.0981
Padding	0.70	0.1479	0.0415	0.0354	0.0377	0.0397
Padding	1.00	0.0262	0.0059	0.0041	0.0078	0.0048
Dummy	0.10	0.7965	0.2787	0.1772	0.1541	0.1857
Dummy	0.30	0.8280	0.3245	0.2106	0.1407	0.1504
Dummy	0.50	0.9137	0.3035	0.2031	0.1783	0.2279
Dummy	0.70	0.8087	0.2860	0.2125	0.1662	0.1431
Dummy	1.00	0.8214	0.2593	0.1902	0.2130	0.1576
Fragmentation	0.10	0.8463	0.2960	0.2098	0.1592	0.1804
Fragmentation	0.30	0.8592	0.2644	0.2296	0.1692	0.1948
Fragmentation	0.50	0.6807	0.2094	0.1626	0.1515	0.1627
Fragmentation	0.70	0.8291	0.2396	0.2190	0.1779	0.1900
Fragmentation	1.00	0.8373	0.2362	0.1960	0.1963	0.2074
Combined	0.10	0.8410	0.1969	0.1941	0.2219	0.2271
Combined	0.30	0.4606	0.1121	0.1077	0.1201	0.1251
Combined	0.50	0.0659	0.0217	0.0136	0.0138	0.0136
Combined	0.70	0.0393	0.0141	0.0074	0.0085	0.0084
Combined	1.00	0.2256	0.0633	0.0489	0.0539	0.0590

Tabella 11: Risultati multiclass open-world sul cohort Instagram. $\overline{P}_8$ è la probabilità media Instagram; G1–G4 riportano i contributi medi assoluti.

Background	$\overline{P}_8$	G1	G2	G3	G4
0.30	0.8103	0.2054	0.2206	0.1825	0.1995
0.40	0.7364	0.2507	0.2434	0.1444	0.0955
0.50	0.8690	0.2368	0.2330	0.1879	0.2094
0.60	0.7120	0.2079	0.2174	0.1594	0.1239
0.70	0.6257	0.1773	0.1744	0.1436	0.1281

Tabella 12: Risultati binary per 15 campioni di ciascun cohort e rapporto. $\overline{P}_M$ è la media di $P(\text{monitored})$; G1–G4 riportano i contributi medi assoluti.

Background	Cohort	$\overline{P}_M$	G1	G2	G3	G4
0.30	Monitored	0.9996	0.1595	0.1787	0.0684	0.0929
0.30	Background	0.0059	0.2339	0.0860	0.0772	0.1014
0.40	Monitored	1.0000	0.1579	0.2757	0.0459	0.0205
0.40	Background	0.0677	0.2465	0.1285	0.0564	0.0703
0.50	Monitored	1.0000	0.1811	0.2237	0.0736	0.0356
0.50	Background	0.0425	0.2584	0.1185	0.0606	0.0597
0.60	Monitored	1.0000	0.1616	0.2110	0.0523	0.0764
0.60	Background	0.0002	0.2477	0.1061	0.0760	0.0700
0.70	Monitored	1.0000	0.0986	0.2590	0.0701	0.0724
0.70	Background	0.0001	0.3056	0.1135	0.0399	0.0428

Tabella 13: Contributi binary medi con segno. Valori positivi aumentano $P(\text{monitored})$ rispetto alle reference; valori negativi la diminuiscono.

Background	Cohort	G1	G2	G3	G4
0.30	Monitored	0.1595	0.1787	0.0684	0.0929
0.30	Background	-0.2339	-0.0860	-0.0727	-0.1014
0.40	Monitored	0.1579	0.2757	0.0459	0.0205
0.40	Background	-0.2022	-0.1285	-0.0404	-0.0612
0.50	Monitored	0.1811	0.2096	0.0736	0.0356
0.50	Background	-0.2584	-0.1185	-0.0343	-0.0464
0.60	Monitored	0.1616	0.2097	0.0523	0.0764
0.60	Background	-0.2477	-0.1061	-0.0760	-0.0700
0.70	Monitored	0.0986	0.2590	0.0701	0.0724
0.70	Background	-0.3056	-0.1135	-0.0399	-0.0408

A.1 Tabelle cross-run

Le tabelle seguenti riportano le medie cross-run, arrotondate a quattro decimali. Le performance includono i CI al 95% sui cinque valori run-level. Le tabelle sintetiche XAI riportano le medie dei cohort primari; tutti i relativi CI, le statistiche Instagram e i delta paired sono disponibili in `global_summary.csv`. Le magnitudini sono in unità di probabilità e non sono quote normalizzate.

Tabella 14: Baseline e defense RF: media e CI al 95% su cinque training run per configurazione, sui test completi.

Defense	Intensità	Accuracy [CI 95%]	Macro-F1 [CI 95%]
Baseline	0.00	0.9831 [0.9791, 0.9865]	0.9826 [0.9794, 0.9860]
Padding	0.10	0.9794 [0.9766, 0.9828]	0.9782 [0.9752, 0.9817]
Padding	0.30	0.9529 [0.9520, 0.9540]	0.9490 [0.9470, 0.9509]
Padding	0.50	0.9024 [0.8922, 0.9142]	0.8950 [0.8845, 0.9075]
Padding	0.70	0.7628 [0.7413, 0.7850]	0.7487 [0.7265, 0.7721]
Padding	1.00	0.4982 [0.4810, 0.5154]	0.4709 [0.4559, 0.4847]
Dummy	0.10	0.9817 [0.9788, 0.9836]	0.9794 [0.9762, 0.9825]
Dummy	0.30	0.9786 [0.9757, 0.9814]	0.9761 [0.9722, 0.9795]
Dummy	0.50	0.9774 [0.9740, 0.9808]	0.9752 [0.9702, 0.9802]
Dummy	0.70	0.9738 [0.9701, 0.9769]	0.9702 [0.9661, 0.9741]
Dummy	1.00	0.9707 [0.9647, 0.9763]	0.9666 [0.9595, 0.9734]
Fragmentation	0.10	0.9777 [0.9729, 0.9814]	0.9759 [0.9715, 0.9794]
Fragmentation	0.30	0.9622 [0.9574, 0.9667]	0.9562 [0.9517, 0.9610]
Fragmentation	0.50	0.9410 [0.9300, 0.9489]	0.9344 [0.9245, 0.9422]
Fragmentation	0.70	0.9295 [0.9250, 0.9340]	0.9222 [0.9166, 0.9279]
Fragmentation	1.00	0.9298 [0.9219, 0.9368]	0.9225 [0.9153, 0.9300]
Combined	0.10	0.9622 [0.9551, 0.9701]	0.9577 [0.9492, 0.9670]
Combined	0.30	0.8449 [0.8395, 0.8505]	0.8327 [0.8259, 0.8385]
Combined	0.50	0.6423 [0.6299, 0.6578]	0.6252 [0.6087, 0.6415]
Combined	0.70	0.4911 [0.4858, 0.4965]	0.4591 [0.4500, 0.4692]
Combined	1.00	0.6618 [0.6477, 0.6762]	0.6355 [0.6238, 0.6470]

Tabella 15: Baseline e defense FOLD: media e CI al 95% su cinque training run per configurazione, sui test completi.

Defense	Intensità	Accuracy [CI 95%]	Macro-F1 [CI 95%]
Baseline	0.00	0.9867 [0.9831, 0.9898]	0.9860 [0.9835, 0.9885]
Padding	0.10	0.9811 [0.9797, 0.9828]	0.9802 [0.9795, 0.9809]
Padding	0.30	0.9614 [0.9574, 0.9661]	0.9573 [0.9527, 0.9629]
Padding	0.50	0.9157 [0.9066, 0.9247]	0.9097 [0.9025, 0.9169]
Padding	0.70	0.8023 [0.7718, 0.8307]	0.7925 [0.7649, 0.8202]
Padding	1.00	0.5927 [0.5814, 0.6076]	0.5746 [0.5652, 0.5892]
Dummy	0.10	0.9859 [0.9831, 0.9887]	0.9841 [0.9809, 0.9872]
Dummy	0.30	0.9856 [0.9834, 0.9879]	0.9837 [0.9810, 0.9864]
Dummy	0.50	0.9831 [0.9797, 0.9862]	0.9813 [0.9776, 0.9849]
Dummy	0.70	0.9865 [0.9831, 0.9896]	0.9853 [0.9819, 0.9882]
Dummy	1.00	0.9808 [0.9760, 0.9856]	0.9787 [0.9740, 0.9841]
Fragmentation	0.10	0.9819 [0.9788, 0.9850]	0.9808 [0.9780, 0.9843]
Fragmentation	0.30	0.9695 [0.9667, 0.9729]	0.9652 [0.9629, 0.9673]
Fragmentation	0.50	0.9506 [0.9453, 0.9551]	0.9452 [0.9399, 0.9506]
Fragmentation	0.70	0.9379 [0.9289, 0.9470]	0.9328 [0.9250, 0.9404]
Fragmentation	1.00	0.9439 [0.9402, 0.9472]	0.9382 [0.9361, 0.9404]
Combined	0.10	0.9659 [0.9583, 0.9735]	0.9633 [0.9562, 0.9700]
Combined	0.30	0.8604 [0.8474, 0.8748]	0.8517 [0.8415, 0.8658]
Combined	0.50	0.6717 [0.6561, 0.6835]	0.6602 [0.6385, 0.6759]
Combined	0.70	0.5441 [0.5168, 0.5715]	0.5214 [0.4882, 0.5509]
Combined	1.00	0.7365 [0.7278, 0.7467]	0.7234 [0.7083, 0.7349]

Tabella 16: FOLD multiclass baseline e defense: probabilità del sito reale e mean $|\phi_g|$ sui 92 siti eleggibili, con peso uguale ai siti. I CI sono in `global_summary.csv`.

Defense	Intensità	$\overline{P}_{\text{sito reale}}$	G1	G2	G3	G4
Baseline	0.00	0.8330	0.3379	0.1793	0.1520	0.1550
Padding	0.10	0.8465	0.3212	0.1813	0.1704	0.1658
Padding	0.30	0.8295	0.2622	0.1902	0.1886	0.1814
Padding	0.50	0.7731	0.2196	0.1767	0.1831	0.1881
Padding	0.70	0.7161	0.2051	0.1622	0.1758	0.1692
Padding	1.00	0.4906	0.1446	0.1131	0.1219	0.1129
Dummy	0.10	0.8415	0.3226	0.1797	0.1697	0.1612
Dummy	0.30	0.8372	0.3272	0.1828	0.1597	0.1598
Dummy	0.50	0.8267	0.3142	0.1843	0.1584	0.1613
Dummy	0.70	0.8338	0.3139	0.1917	0.1618	0.1585
Dummy	1.00	0.8401	0.3054	0.1844	0.1704	0.1720
Fragmentation	0.10	0.8318	0.3046	0.1749	0.1707	0.1723
Fragmentation	0.30	0.7995	0.2838	0.1670	0.1734	0.1673
Fragmentation	0.50	0.8160	0.2643	0.1797	0.1802	0.1827
Fragmentation	0.70	0.7962	0.2698	0.1702	0.1753	0.1729
Fragmentation	1.00	0.7953	0.3117	0.1605	0.1573	0.1577
Combined	0.10	0.8189	0.2614	0.1905	0.1789	0.1804
Combined	0.30	0.7389	0.2126	0.1591	0.1830	0.1782
Combined	0.50	0.5889	0.1757	0.1352	0.1409	0.1384
Combined	0.70	0.4336	0.1318	0.0985	0.1061	0.1008
Combined	1.00	0.6248	0.2071	0.1407	0.1427	0.1292

Tabella 17: Open-world RF e FOLD: media e CI al 95% dei cinque valori run-level per rapporto.

Background	Modello	Accuracy [CI 95%]	Macro-F1 [CI 95%]
0.30	RF	0.9686 [0.9649, 0.9724]	0.9721 [0.9694, 0.9747]
0.30	FOLD	0.9704 [0.9670, 0.9737]	0.9708 [0.9682, 0.9742]
0.40	RF	0.9707 [0.9687, 0.9728]	0.9705 [0.9691, 0.9723]
0.40	FOLD	0.9758 [0.9719, 0.9797]	0.9724 [0.9677, 0.9771]
0.50	RF	0.9722 [0.9694, 0.9749]	0.9671 [0.9653, 0.9688]
0.50	FOLD	0.9787 [0.9764, 0.9810]	0.9703 [0.9666, 0.9739]
0.60	RF	0.9730 [0.9700, 0.9757]	0.9629 [0.9580, 0.9662]
0.60	FOLD	0.9834 [0.9806, 0.9862]	0.9721 [0.9674, 0.9766]
0.70	RF	0.9776 [0.9761, 0.9794]	0.9599 [0.9572, 0.9637]
0.70	FOLD	0.9850 [0.9833, 0.9866]	0.9660 [0.9618, 0.9696]

Tabella 18: Detection RF: media e CI al 95% sui cinque run. TPR e FPR usano soglia > 0.5; AUC considera tutte le soglie.

Background	TPR [CI 95%]	FPR [CI 95%]	AUC [CI 95%]
0.30	0.9642 [0.9577, 0.9707]	0.0125 [0.0099, 0.0164]	0.9929 [0.9917, 0.9939]
0.40	0.9642 [0.9577, 0.9707]	0.0140 [0.0097, 0.0182]	0.9926 [0.9916, 0.9936]
0.50	0.9642 [0.9577, 0.9707]	0.0161 [0.0138, 0.0183]	0.9924 [0.9911, 0.9936]
0.60	0.9642 [0.9577, 0.9707]	0.0186 [0.0166, 0.0207]	0.9925 [0.9911, 0.9936]
0.70	0.9642 [0.9577, 0.9707]	0.0151 [0.0119, 0.0193]	0.9925 [0.9913, 0.9934]

Tabella 19: Detection FOLD: media e CI al 95% sui cinque run. TPR e FPR usano soglia > 0.5; AUC considera tutte le soglie.

Background	TPR [CI 95%]	FPR [CI 95%]	AUC [CI 95%]
0.30	0.9893 [0.9834, 0.9955]	0.0447 [0.0342, 0.0533]	0.9968 [0.9952, 0.9985]
0.40	0.9898 [0.9865, 0.9932]	0.0258 [0.0190, 0.0355]	0.9977 [0.9964, 0.9989]
0.50	0.9867 [0.9822, 0.9913]	0.0152 [0.0116, 0.0189]	0.9979 [0.9971, 0.9987]
0.60	0.9845 [0.9797, 0.9887]	0.0098 [0.0071, 0.0124]	0.9982 [0.9972, 0.9988]
0.70	0.9867 [0.9825, 0.9910]	0.0096 [0.0079, 0.0112]	0.9981 [0.9970, 0.9991]

Tabella 20: Open-world FOLD multiclass: probabilità del sito reale e mean $|\phi_g|$ sui 92 siti eleggibili; CI disponibili nei CSV.

Background	$\overline{P}_{\text{sito reale}}$	G1	G2	G3	G4
0.30	0.8000	0.2856	0.1789	0.1559	0.1711
0.40	0.7925	0.2962	0.1839	0.1458	0.1585
0.50	0.7805	0.2796	0.1749	0.1523	0.1665
0.60	0.7578	0.2903	0.1641	0.1418	0.1542
0.70	0.7554	0.2829	0.1714	0.1414	0.1526

Tabella 21: Binary FOLD: probabilità media monitored e magnitudini G1–G4. Monitored: 92 siti, 266 tracce distinte; background: 266 osservazioni per rapporto, 263–265 tracce distinte. CI disponibili nei CSV.

Background	Cohort	$\overline{P}_M$	G1	G2	G3	G4
0.30	Monitored	0.9968	0.2845	0.1162	0.0680	0.0626
0.30	Background	0.0332	0.2428	0.1109	0.0795	0.0768
0.40	Monitored	0.9993	0.2779	0.1339	0.0674	0.0652
0.40	Background	0.0304	0.2504	0.1172	0.0740	0.0737
0.50	Monitored	0.9823	0.3061	0.1087	0.0627	0.0614
0.50	Background	0.0067	0.2897	0.0974	0.0626	0.0624
0.60	Monitored	0.9931	0.2986	0.1122	0.0651	0.0640
0.60	Background	0.0165	0.2797	0.0902	0.0704	0.0685
0.70	Monitored	0.9962	0.2746	0.1353	0.0710	0.0588
0.70	Background	0.0068	0.3187	0.0870	0.0521	0.0508

A.2 Risultati supplementari nel repository

I risultati numerici finali sono in `analysis/cross_run/summary_fast/`. `global_summary.csv` contiene medie e CI delle attribuzioni, probabilità e delta; `site_summary.csv` conserva le statistiche site/run. `coverage.csv` documenta osservazioni, tracce distinte e run disponibili. `dominant_summary.csv`, `dominant_sites.csv` e `heatmap.csv` descrivono i risultati per sito; `delta_raw_long.csv` e `pairing.csv` conservano differenze paired e verifica del matching. `performance_raw.csv` e `performance_summary.csv` distinguono valori run-level e loro medie con CI.

Le 85 figure complete sono in `analysis/cross_run/figures_fast/`, organizzate in `baseline/`, `defenses/padding/`, `defenses/dummy/`, `defenses/fragmentation/`, `defenses/combined/`, `openworld/`, `performance/fold/` e `performance/forest/`. Per ogni configurazione multiclass sono disponibili heatmap e dominant-group chart; i grafici delle famiglie riportano magnitudini, delta e probabilità, e quelli binary distinguono magnitudine e segno. Il corpo del report seleziona le figure necessarie al confronto; le restanti analisi costituiscono il materiale supplementare.

Tabella 22: Binary FOLD: contributi medi con segno a $P(\text{monitored})$. Le medie sono positive per monitored e negative per background; i singoli contributi possono avere segni diversi. CI disponibili nei CSV.

Background	Cohort	G1	G2	G3	G4
0.30	Monitored	0.2775	0.0994	0.0623	0.0576
0.30	Background	-0.2299	-0.0974	-0.0680	-0.0716
0.40	Monitored	0.2710	0.1137	0.0599	0.0548
0.40	Background	-0.2388	-0.1015	-0.0674	-0.0618
0.50	Monitored	0.3017	0.0858	0.0492	0.0456
0.50	Background	-0.2832	-0.0946	-0.0578	-0.0576
0.60	Monitored	0.2895	0.0916	0.0567	0.0553
0.60	Background	-0.2743	-0.0832	-0.0648	-0.0611
0.70	Monitored	0.2675	0.1099	0.0662	0.0527
0.70	Background	-0.3169	-0.0850	-0.0470	-0.0443